

UNIVERSIDADE PRESBITERIANA MACKENZIE

Fernanda Pauli de Oliveira – 10736757

Henrique Sarmento – 10738262

Milena Dias Gouveia – 10746134

Nicolly Falcão da Silva – 10746541

**SISTEMA DE RECOMENDAÇÃO DE ESPÉCIES NATIVAS PARA
REFLORESTAMENTO E ARBORIZAÇÃO URBANA (ODS 15)**

Brasil

2026

SUMÁRIO

1 INTRODUÇÃO	3
1.1 Contexto	3
1.2 Motivação e justificativa	3
1.3 Objetivos	4
1.3.1 Objetivo Geral	4
1.3.2 Objetivos Específicos	4
1.4 Definição da Base de Dados	5
1.4.1 Forma e Período de Coleta	6
1.4.2 Limitações dos Dados	6
1.5 Visão Geral do Pipeline de Dados e Modelagem Híbrida	6
1.6 Cronograma de Execução	7
1.7 Repositório no GitHub.....	8
1.8 Critérios de Validação e Entregáveis	9
2 REFERENCIAL TEÓRICO	9
2.1 Teoria do Nicho Ecológico e Adequabilidade Ambiental.....	10
2.2 Filtragem Baseada em Conteúdo e Vetorização de Atributos	11
2.3 Filtragem Colaborativa com Feedback Implícito e Fitossociologia	12
2.4 Arquitetura Híbrida em Duas Fases (Two-Stage Hybrid Recommendation).....	14
2.5 Desafios de Engenharia de Dados: Viés Amostral e Resolução Taxonômica	16
2.6 Métricas de Avaliação Top-N e Diversidade Funcional	17
3 REFERÊNCIAS	19

1 INTRODUÇÃO

1.1 Contexto

A degradação florestal acelerada e a perda contínua de biodiversidade constituem crises ambientais de escala global que exigem respostas estruturadas e apoiadas em metodologias analíticas robustas. Esse cenário alinha-se diretamente ao Objetivo de Desenvolvimento Sustentável 15 (ODS 15) estabelecido pela Organização das Nações Unidas (ONU), cuja finalidade primordial consiste em proteger, recuperar e promover o uso sustentável dos ecossistemas terrestres, combatendo a desertificação e revertendo a degradação da terra.

Iniciativas de recomposição florestal no meio rural e de expansão da arborização em ambientes urbanos enfrentam índices expressivos de mortalidade precoce de mudas decorrentes de escolhas inadequadas de espécies vegetais. A sobrevivência das plantas depende estritamente da compatibilidade entre as variáveis do terreno de plantio — tais como propriedades físico-químicas do solo, amplitude térmica anual, regime pluviométrico e índice de insolação — e a amplitude ecológica suportada pela espécie. Quando tais condicionantes não são criteriosamente comparadas antes do plantio, o estabelecimento das populações vegetais fica comprometido, inviabilizando projetos ecológicos e dispersando investimentos socioeconômicos.

A ciência de dados e os algoritmos de recomendação oferecem instrumentos capazes de aproximar o conhecimento botânico especializado das decisões de campo. A consolidação de catálogos botânicos abertos associada a modelos de *Machine Learning* permite estruturar um ecossistema preditivo no qual o perfil de cada terreno é processado de forma automática, garantindo a seleção de espécies nativas resilientes e funcionalmente complementares.

1.2 Motivação e justificativa

A relevância e justificativa deste projeto repousam sobre impactos técnicos, ambientais e econômicos mensuráveis:

- **Aumento na taxa de sobrevivência:** O fornecimento de prescrições botânicas customizadas às restrições do sítio ecológico reduz drasticamente as falhas de estabelecimento radicular e os índices de replantio;

- **Eficiência na destinação de recursos:** Viveiros florestais e secretarias municipais otimizam seus custos de aquisição e logística de transporte de mudas ao priorizar espécies comprovadamente adaptadas à região;

- **Fortalecimento das cadeias ecológicas nativas:** A recomposição vegetal orientada por dados de coocorrência favorece a atração de polinizadores, estimula a dispersão de sementes pela fauna local e restaura os serviços ecossistêmicos essenciais (infiltração de água no lençol freático, contenção de erosão e redução de ilhas de calor urbanas).

Ao traduzir parâmetros botânicos e registros florestais dispersos em recomendações ranqueadas e explicáveis, o sistema atua como uma ponte estratégica entre as evidências científicas e os tomadores de decisão em políticas públicas e restauração ambiental privada.

1.3 Objetivos

1.3.1 Objetivo Geral

Desenvolver um sistema de recomendação híbrido de espécies arbóreas e vegetais nativas para restauração florestal e arborização urbana, integrando atributos ecológicos de adequabilidade ambiental (conteúdo) e padrões empíricos de coocorrência em parcelas inventariadas (colaboração com feedback implícito).

1.3.2 Objetivos Específicos

Para concretizar o objetivo geral, serão cumpridas as seguintes metas específicas:

- **Coleta e integração:** Consolidar uma base unificada a partir de fontes públicas abertas de dados botânicos e inventários florestais governamentais (Flora e Funga do Brasil/JBRJ, Inventário Florestal Nacional/SFB e GBIF);
- **Tratamento e engenharia de dados:** Executar resolução taxonômica automatizada de nomes científicos, mitigar viés de superamostragem geográfica via *spatial thinning* e imputar dados faltantes por inferência biológica fundamentada em hierarquia taxonômica;
- **Modelagem híbrida integrada:** Desenvolver o módulo de Filtragem Baseada em Conteúdo para determinar a adequabilidade das espécies ao nicho abiótico do terreno (solo, precipitação, temperatura e radiação solar) e o módulo de Filtragem Colaborativa fundamentado em Feedback Implícito, estruturando Unidades Amostrais do IFN como 'usuários', espécies como 'itens' e contagens de coocorrência como sinal de confiança de associações ecológicas sinérgicas;
- **Avaliação Top-N:** Validar o desempenho do recomendador por meio de métricas consolidadas em sistemas de recomendação (*Precision@K*, *Recall@K*, *NDCG@K*) complementadas por índices de diversidade taxonômica e funcional.

1.4 Definição da Base de Dados

A construção do recomendador utilizará um *dataset* integrado, formado pela fusão de três grandes repositórios de dados botânicos e florestais de domínio público:

1. Flora e Funga do Brasil (Jardim Botânico do Rio de Janeiro - JBRJ): Atua como catálogo taxonômico e descritor de conteúdo dos 'itens' (espécies). Fornece dados morfológicos, formas de vida, substrato, biomas de ocorrência nativa, endemismo e espectro de tolerância à luz. Link de referência: ipt.jbrj.gov.br/jbrj/resource?r=lista_especies_flora_brasil.

2. Inventário Florestal Nacional (Serviço Florestal Brasileiro - SFB / MAPA): Fornece dados sistemáticos de campo coletados em malha regular de conglomerados pelo território nacional. Informa a presença física, abundância e dominância de indivíduos vegetais vivos em parcelas de 20x20 m, acompanhados de laudos de

caracterização pedológica (análises físicas e químicas do solo). Constitui a base primária da matriz parcela-espécie para a filtragem colaborativa. Links de referência: dados.florestal.gov.br/pt_BR/dataset/ifn-painel-de-dados-biofisicos_disp-set2025 e dados.florestal.gov.br/pt_BR/dataset/solos_ifn.

3. Global Biodiversity Information Facility (GBIF): Repositório global de ocorrências georreferenciadas que provê coordenadas geográficas de registros botânicos coletados por pesquisadores, herbários e coleções científicas. Utilizado para mapeamento contínuo de densidade espacial e enriquecimento do modelo ecológico regional via biblioteca pygbif. Link de referência: gbif.org.

1.4.1 Forma e Período de Coleta

Os dados serão extraídos através das APIs públicas e arquivos tabulares estruturados (CSV/Parquet) disponibilizados pelas instituições supracitadas, filtrando o horizonte temporal dos últimos 10 a 15 anos para garantir relevância climática atual. As observações são registradas por pesquisadores, botânicos e expedições governamentais de mapeamento territorial.

1.4.2 Limitações dos Dados

As principais limitações incluem potenciais desbalanceamentos geográficos (regiões próximas a centros de pesquisa possuem mais ocorrências cadastradas), uso de sinônimos taxonômicos inconsistentes entre as bases e a presença de dados faltantes referentes à tolerância hídrica e química do solo em espécies menos documentadas.

1.5 Visão Geral do Pipeline de Dados e Modelagem Híbrida

O pipeline de dados idealizado seguirá um fluxo automatizado de transformação em seis fases sequenciais:

1. **Ingestão:** Extração programática e consolidação dos repositórios botânicos e pedológicos;
2. **Harmonização:** Padronização taxonômica centralizada pela base do JBRJ e subamostragem espacial (*spatial thinning*) no GBIF para regularizar a densidade espacial;
3. **Engenharia de Recursos:** Vetorização das características ambientais do terreno e das plantas (One-Hot Encoding de variáveis nominais e normalização de atributos contínuos); montagem da matriz esparsa de coocorrência parcela-espécie;
4. **Fase 1 — Filtragem por Conteúdo:** Avaliação da compatibilidade física entre terreno e espécies através de Similaridade do Cosseno, podando espécies inaptas ao nicho abiótico local;
5. **Fase 2 — Ranqueamento Colaborativo:** Aplicação de decomposição de matrizes com feedback implícito (modelo ALS - *Alternating Least Squares*) sobre a matriz de parcelas do IFN, ponderando espécies candidatas com base em padrões de convivência florestal bem-sucedida;
6. **Recomendação Top-N:** Produção da lista final ordenada contendo as espécies prioritárias para o plantio, com métricas de explicabilidade associadas ao solo e ao bioma.

1.6 Cronograma de Execução

O cronograma de execução foi atualizado em 30 de setembro de 2026. As etapas com período anterior a essa data estão marcadas como concluídas; as etapas restantes foram acrescentadas para contemplar a validação das fórmulas, a revisão metodológica, a documentação e a entrega final. O arquivo auxiliar Cronograma_ODS15_Segundo_Semestre_2026.xlsx deve permanecer como controle detalhado do projeto.

Quadro 1 – Cronograma atualizado de execução do projeto.

Período	Atividade	Situação em 30/09/2026	Observação
01–15 jul. 2026	Definição do problema, objetivos e escopo do sistema	Concluída	Escopo do ODS 15 definido.
16–31 jul. 2026	Levantamento bibliográfico e seleção das fontes de dados	Concluída	Referencial e fontes JBRJ, IFN/SFB e GBIF registrados.
01–15 ago. 2026	Coleta e integração inicial dos dados	Concluída	Estrutura da base integrada planejada.
16–31 ago. 2026	Harmonização taxonômica e tratamento de dados	Concluída	Etapas de <i>spatial thinning</i> e resolução de sinonímias previstas.
01–30 set. 2026	Engenharia de atributos e modelagem híbrida	Concluída	Pipeline e equações do modelo documentados.
01–15 out. 2026	Revalidação das fórmulas, métricas e consistência metodológica	Em andamento	Conferir implementação, símbolos, índices e hipóteses.
16–31 out. 2026	Testes, avaliação Top- <i>N</i> e análise de diversidade funcional	Pendente	Executar Precision@ <i>K</i> , Recall@ <i>K</i> , NDCG@ <i>K</i> e ILD.
01–15 nov. 2026	Revisão do texto, referências, ABNT e documentação do repositório	Pendente	Atualizar resultados, limitações e README.
16–30 nov. 2026	Entrega e apresentação do projeto	Pendente	Gerar versão final e materiais de apresentação.

Fonte: elaborado pelos autores (2026).

1.7 Repositório no GitHub

O código-fonte, notebooks de exploração e documentação do projeto encontram-se disponíveis publicamente no repositório: <https://github.com/henrisarmento/ProjetoAplicado3>

1.8 Critérios de Validação e Entregáveis

Para evitar que a recomendação seja avaliada apenas pela qualidade do código ou pela aparência da lista final, o projeto adotará critérios de validação técnica, ecológica e de reprodutibilidade. Esses critérios deverão ser verificados antes da entrega final e registrados no repositório do projeto.

- Validação técnica: conferir a integridade dos dados, a resolução taxonômica, o tratamento de valores ausentes, a ausência de vazamento de dados entre treino e teste e a execução determinística do pipeline.
- Validação do modelo: comparar o desempenho do filtro baseado em conteúdo, do ranqueamento colaborativo e da arquitetura híbrida usando Precision@K, Recall@K, NDCG@K e Diversidade Intra-Lista (ILD), com registro dos parâmetros utilizados.
- Validação ecológica: verificar se as espécies recomendadas são nativas da região de interesse, compatíveis com as condições edafoclimáticas informadas e coerentes com as restrições de conservação aplicáveis. A recomendação deverá apoiar a decisão técnica, não substituir a avaliação de profissional habilitado.
- Reprodutibilidade: disponibilizar no GitHub os notebooks, scripts, versões das fontes de dados, dicionário de variáveis, instruções de execução e registro das limitações conhecidas.

Ao final da etapa, os entregáveis previstos são: (a) base integrada documentada; (b) pipeline de pré-processamento; (c) modelo híbrido treinado e avaliado; (d) relatório de métricas e diversidade; (e) lista de recomendações com justificativas; e (f) documentação final do projeto.

2 REFERENCIAL TEÓRICO

O embasamento científico do presente trabalho articula fundamentos da ecologia de paisagens e restauração florestal com a teoria computacional de sistemas de recomendação, aprendizado de máquina e recuperação de informação. A integração desses domínios viabiliza a transposição de conceitos ecológicos — como nicho fundamental, nicho efetivo e sucessão vegetal — para formulações algorítmicas rigorosas de filtragem baseada em conteúdo e filtragem colaborativa.

2.1 Teoria do Nicho Ecológico e Adequabilidade Ambiental

A distribuição geográfica e a sobrevivência de comunidades vegetais são governadas pelos princípios da Teoria do Nicho Ecológico. O conceito, introduzido pioneiramente por Grinnell (1917) ao enfatizar as restrições ambientais de habitat, foi formalizado matematicamente por Hutchinson (1957) como um hipervolume n -dimensional delimitado por eixos de variáveis bióticas e abióticas, dentro do qual uma espécie é capaz de manter populações viáveis sem declínio demográfico contínuo.

Hutchinson (1957) estabeleceu uma distinção elementar entre dois estados de nicho:

1. Nicho Fundamental (N_F): Compreende o espectro integral de condições físicas e fisiológicas (tais como pH do solo, disponibilidade de nutrientes, radiação solar e amplitude de temperatura) em que os indivíduos de uma espécie conseguem sobreviver e se reproduzir na ausência de competição, herbivoria ou patógenos;

2. Nicho Efetivo ou Realizado (N_R): Representa a fração restrita do nicho fundamental efetivamente ocupada pela espécie na presença de interações biológicas competitivas, limitações de dispersão de sementes e barreiras biogeográficas.

Posteriormente, Soberón (2007) consolidou o diagrama BAM (Biótica, Abiótica e Movimentação), postulando que a presença estável de uma espécie no espaço requer a conjunção de condições abióticas favoráveis (vetor ambiental A), interações biológicas compatíveis (vetor de facilitação e simbiose B) e capacidade de acessibilidade geográfica (M).

No contexto da restauração ecológica e recomposição de matas degradadas, a sobrevivência inicial de mudas florestais é crítica nos dois primeiros anos após o plantio (BRANCALION et al., 2019; CHAZDON, 2014). Durante essa janela, as mudas encontram-se altamente expostas ao estresse hídrico, choque térmico e toxidez ou deficiência mineral do solo. Consequentemente, a modelagem de adequabilidade ambiental opera como a verificação algorítmica de que o ponto amostral do terreno de plantio situa-se no interior do hipervolume do nicho fundamental da espécie vegetal recomendada, minimizando mortalidades por incompatibilidade fisiológica básica.

2.2 Filtragem Baseada em Conteúdo e Vetorização de Atributos

Os sistemas de recomendação baseados em conteúdo (*Content-Based Filtering* — CBF) fundam-se no princípio de que as preferências ou restrições de uma entidade de entrada devem ser atendidas por itens que compartilhem atributos intrínsecos e propriedades descritivas com esse perfil de necessidade (RICCI; ROKACH; SHAPIRA, 2011; LOPS; DE GEMMIS; SEMERARO, 2011).

No modelo ecológico formulado, o 'perfil de restrições do usuário' consiste no vetor representativo do terreno ou microrregião de plantio, denotado por $u \in \mathbb{R}^d$, cujas dimensões expressam as características edafoclimáticas locais (tipo de bioma, classe textural do solo, teor de acidez/pH, drenagem hídrica e radiação solar média). Paralelamente, cada espécie botânica catalogada constitui um item caracterizado por seu vetor descritivo $i \in \mathbb{R}^d$, que documenta as tolerâncias e preferências funcionais da planta (estrato vegetativo, exigência de luz, tolerância ao encharcamento e forma biológica).

Para viabilizar a comparação geométrica entre o vetor de entrada u e o vetor do item i , adota-se o Modelo de Espaço Vetorial (Vector Space Model), historicamente consolidado em recuperação de informação por Salton e McGill (1983) e formalizado por Aggarwal (2016). Os atributos categóricos nominais passam por codificação vetorial via One-Hot Encoding (OHE), enquanto os atributos numéricos contínuos (faixas térmicas e pluviométricas) sofrem normalização min-max ou padronização z-score.

A proximidade angular e a compatibilidade de conteúdo entre a necessidade do terreno u e a espécie i são mensuradas por meio da Similaridade do Cosseno (SALTON; MCGILL, 1983; RICCI; ROKACH; SHAPIRA, 2011), expressa pela Equação (1):

$$\text{Simil}(u, i) = \frac{u \cdot i}{\|u\| \|i\|} = \frac{\sum_k u_k i_k}{\sqrt{\sum_k u_k^2} \sqrt{\sum_k i_k^2}} \quad (1)$$

O valor resultante de $\text{Simil}(u, i) \in [0, 1]$ traduz a aderência fisiológica da espécie às restrições ecológicas do terreno. Caso uma variável crítica possua restrição rígida inegociável — por exemplo, uma planta higrófila obrigatória em terreno com déficit hídrico severo —, penalizações multiplicativas atuam para zerar a pontuação de relevância, assegurando que o recomendador de conteúdo funcione como um rigoroso filtro abiótico inicial.

2.3 Filtragem Colaborativa com Feedback Implícito e Fitossociologia

Embora a filtragem baseada em conteúdo assegure que a planta possui capacidade fisiológica de tolerar o clima e o solo de um local (nicho fundamental), ela falha em capturar as dinâmicas de coexistência ecológica, facilitação biológica e sucesso prático de sucessão florestal (nicho realizado) (LEGENDRE; LEGENDRE, 2012; CHAZDON, 2014).

A Filtragem Colaborativa (*Collaborative Filtering* — CF) contorna essa limitação ao inferir associações latentes a partir de padrões históricos de comportamento observado (KOREN; BELL; VOLINSKY, 2009). No contexto deste projeto aplicado, responde-se explicitamente à definição da interação colaborativa:

- Entidades de Usuário (u): Unidades amostrais físicas de campo, consubstanciadas nas parcelas inventariadas padronizadas do Inventário Florestal Nacional (IFN) e em grids territoriais com conglomerados de ocorrências do GBIF;
- Entidades de Item (i): Espécies florestais e arbóreas nativas;
- Matriz de Interação (R): Estrutura de dimensão $M \times N$, na qual M representa o total de parcelas inventariadas e N o número de espécies botânicas conhecidas.

Diferentemente de sistemas de comércio eletrônico, onde os usuários fornecem avaliações explícitas (pontuações de 1 a 5 estrelas), dados de ecologia florestal configuram um problema clássico de Feedback Implícito (Implicit Feedback) (HU; KOREN; VOLINSKY, 2008). Quando uma espécie não é registrada em uma determinada parcela ($r_{ui} = 0$), tal dado não denota aversão ou rejeição ativa; indica meramente que a espécie não foi observada, seja por ausência real ou por limitações

estocásticas de dispersão. Em contrapartida, quando indivíduos vivos da espécie são registrados na parcela ($r_{ui} > 0$), sua contagem numérica ou frequência relativa atesta empiricamente a capacidade daquela planta de colonizar e sobreviver naquele ambiente.

Para tratar essa assimetria, adota-se o formalismo de Hu, Koren e Volinsky (2008), decompondo as observações r_{ui} em duas variáveis distintas:

Preferência Binária (p_{ui}): Indica se existe evidência positiva de presença e viabilidade da espécie i na parcela u :

$$p_{ui} = \begin{cases} 1, & \text{se } r_{ui} > 0 \\ 0, & \text{se } r_{ui} = 0 \end{cases} \quad (2)$$

Confiança da Observação (c_{ui}): Quantifica o grau de certeza da preferência ecológica, proporcional à densidade de indivíduos observados:

$$c_{ui} = 1 + \alpha r_{ui} \quad (3)$$

onde α é um hiperparâmetro de taxa de aprendizado que calibra o impacto da densidade vegetal observada no cálculo da confiança.

A predição da afinidade latente entre a parcela u e a espécie i é obtida pelo produto escalar dos respectivos vetores latentes $\mathbf{x}_u, \mathbf{y}_i \in \mathbb{R}^f$ de dimensionalidade reduzida ($f \ll \min(M, N)$):

$$\hat{p}_{ui} = \mathbf{x}_u^T \mathbf{y}_i \quad (4)$$

O treinamento do modelo dá-se pela minimização da função de custo regularizada ponderada pela confiança, resolvida por Mínimos Quadrados Alternados (*Alternating Least Squares* — ALS) (HU; KOREN; VOLINSKY, 2008; KOREN; BELL; VOLINSKY, 2009):

$$\mathcal{L}_{\text{ALS}} = \sum_{u,i} c_{ui} (p_{ui} - \mathbf{x}_u^T \mathbf{y}_i)^2 + \lambda \left(\sum_u \|\mathbf{x}_u\|^2 + \sum_i \|\mathbf{y}_i\|^2 \right) \quad (5)$$

onde λ representa o parâmetro de regularização L_2 para prevenir sobreajuste (*overfitting*).


Do ponto de vista fitossociológico, a decomposição em fatores latentes extrai 'dimensões ecológicas ocultas' — tais como afinidades micorrízicas no subsolo, complementariedade de estratos de copa e tolerâncias a regimes específicos de perturbação — que não se encontram expressas textualmente nos catálogos morfológicos, permitindo predizer quais espécies possuem sinergia comunitária para prosperar em conjunto (LEGENDRE; LEGENDRE, 2012).

2.4 Arquitetura Híbrida em Duas Fases (Two-Stage Hybrid Recommendation)

Conforme demonstrado por Burke (2002) e reiterado por Ricci, Rokach e Shapira (2011), sistemas de recomendação puros sofrem de limitações estruturais: a filtragem colaborativa é severamente impactada pelo problema do *cold-start* (inviabilidade de recomendar itens inéditos ou atender terrenos recém-cadastrados sem parcelas vizinhas inventariadas), ao passo que a filtragem por conteúdo sofre de *overspecialization* (incapacidade de surpreender o usuário com associações inovadoras ou complementares).

Para superar tais fragilidades no domínio botânico, o presente projeto adota uma Arquitetura Híbrida Sequencial em Duas Fases (Two-Stage Cascade Hybrid), conforme ilustrado na Figura 1:

Figura 1 – Arquitetura do Recomendador Híbrido em Duas Fases para Restauração Florestal.



Fonte: Autores (2026).

Na Fase 1, a filtragem baseada em conteúdo atua como um gerador de candidatas (candidacy generation), avaliando o universo total de espécies catalogadas e eliminando sumariamente qualquer táxon cujos limites fisiológicos sejam violados pelas condições do terreno de entrada. O resultado é um subconjunto reduzido de candidatas ecologicamente viáveis, C_u .

Na Fase 2, o ranqueamento refinado (*reranking*) é processado pelo módulo colaborativo alimentado pela matriz de coocorrência do IFN. A pontuação híbrida final $S(u, i)$ para cada espécie $i \in C_u$ é calculada por combinação linear ponderada expressa pela Equação (6):

$$S(u, i) = \beta \cdot \text{Simil}_{\text{CBF}}(u, i) + (1 - \beta) \cdot \hat{p}_{ui}^{\text{CF}} \quad (6)$$

onde $\beta \in [0, 1]$ é um coeficiente calibrador de peso entre a estrita compatibilidade abiótica e o incentivo a coocorrências fitossociológicas comprovadas em parcelas semelhantes.

2.5 Desafios de Engenharia de Dados: Viés Amostral e Resolução Taxonômica

O emprego de repositórios de dados abertos integrados em tarefas de aprendizado de máquina demanda intervenções técnicas para evitar o aprendizado de artefatos espúrios e distorções metodológicas:

1. Viés de Amostragem Geográfica (Spatial Sampling Bias): Conforme diagnosticado por Meyer et al. (2015) e Beck et al. (2014), os dados de ocorrência de biodiversidade em plataformas abertas como o GBIF apresentam fortes distorções espaciais, com adensamento desproporcional de registros nas imediações de universidades, centros urbanos e rodovias pavimentadas. Se essa assimetria não for corrigida, o modelo tenderá a recomendar espécies sinantrópicas ou de borda em detrimento de espécies nativas clímax raras. Para mitigar o problema, emprega-se a técnica de subamostragem espacial (*spatial thinning*), que impõe uma distância euclidiana mínima entre coordenadas de registro de uma mesma espécie, expurgando sobreposições artificiais de coletas reiteradas no mesmo ponto geográfico.

2. Resolução de Entidades e Harmonização Taxonômica: A taxonomia botânica evolui constantemente através de revisões morfológicas e filogenômicas, gerando proliferação de sinônimos nomenclaturais para a mesma entidade biológica (BFG, 2015). A ocorrência de um espécime catalogado sob o basônimo original em um herbário e sob a nova combinação em outro geraria vetores fragmentados na matriz

colaborativa. Torna-se indispensável o emprego de rotinas de resolução de entidades apoiadas no vocabulário controlado oficial da *Flora e Funga do Brasil* (JBRJ, 2026), unificando sinonímias no táxon aceito válido antes da vetorização.

3. Tratamento de Dados Esparsos e Missing Values: Em atributos ambientais contínuos (como amplitude ótima de pH e condutividade elétrica do solo), a ausência de registros para espécies pouco estudadas é tratada por imputação estatística fundamentada em conservadorismo filogenético, agregando valores médios observados no respectivo gênero ou família botânica.

2.6 Métricas de Avaliação Top-N e Diversidade Funcional

A eficácia de um sistema de recomendação ecológico difere substancialmente da validação de classificadores supervisionados clássicos (avaliados por acurácia ou matriz de confusão simples). O propósito primordial consiste em entregar ao profissional de campo uma lista curta, altamente relevante e ordenada de K espécies prioritárias (listas Top- K) (CREMONESI; KOREN; TURRIN, 2010; RICCI; ROKACH; SHAPIRA, 2011).

Para tanto, adotam-se as seguintes métricas de avaliação:

Precisão em K (Precision@ K)

Mede a proporção de espécies recomendadas no conjunto das top- K posições que são verdadeiramente viáveis e compatíveis com as características da parcela de teste (MANNING; RAGHAVAN; SCHÜTZE, 2008):

$$\text{Precision@}K = \frac{| \text{Recomendacoes@}K \cap \text{Relevantes} |}{K} \quad (7)$$

Revocação em K (Recall@ K)

Mensura a proporção de espécies sabidamente viáveis para aquele microambiente que o sistema foi capaz de recuperar dentro do corte de K recomendações:

$$\text{Recall}@K = \frac{|\text{Recomendacoes}@K \cap \text{Relevantes}|}{|\text{Relevantes}|} \quad (8)$$

Ganho Cumulativo Descontado Normalizado (NDCG@K)

Formulado por Järvelin e Kekäläinen (2002), o NDCG avalia a qualidade da ordenação das recomendações, atribuindo maior recompensa quando as espécies mais resilientes e de maior sinergia ecológica são posicionadas no topo da lista. O Ganho Cumulativo Descontado (*Discounted Cumulative Gain* — DCG) na posição K é dado pela Equação (9):

$$\text{DCG}@K = \sum_{i=1}^K \frac{2^{\text{rel}_i} - 1}{\log_2(i + 1)} \quad (9)$$

onde rel_i representa a relevância atribuída à espécie na posição i . O $\text{NDCG}@K$ corresponde à razão entre o $\text{DCG}@K$ e o ganho ideal ($\text{IDCG}@K$), expresso pela Equação (10):

$$\text{NDCG}@K = \frac{\text{DCG}@K}{\text{IDCG}@K} \in [0, 1] \quad (10)$$

Diversidade Intra-Lista e Resiliência Ecológica

Em sistemas de recomendação de produtos, listas hiper-homogêneas (ex: sugerir cinco filmes da mesma franquia) prejudicam a experiência do usuário (ZIEGLER et al., 2005). Na restauração florestal, esse fenômeno acarreta riscos ainda mais graves: recomendar espécies pertencentes a uma única família botânica ou a um único grupo sucessional (exclusivamente pioneiras ou exclusivamente clímax) compromete a resiliência ecológica do plantio, aumentando a vulnerabilidade a pragas e impedindo a formação de estratos vegetais balanceados (CHAZDON, 2014; BRANCALION et al., 2019).

Para avaliar se o modelo preserva a diversidade botânica, aplica-se a métrica de Diversidade Intra-Lista (*Intra-List Diversity* — ILD), proposta por Ziegler et al. (2005), conforme a Equação (11):

$$ILD(L) = \frac{2}{|L|(|L|-1)} \sum_{i \in L} \sum_{j \in L, j > i} d(i, j) \quad (11)$$

onde L denota a lista Top- K recomendada, $|L|$ representa a sua cardinalidade (número de itens) e $d(i, j)$ expressa a dissimilaridade entre as espécies i e j (mensurada por distância taxonômica ou dissimilaridade de traços funcionais botânicos). A otimização conjunta do NDCG@ K e da ILD assegura a entrega de recomendações agronomicamente seguras, resilientes e promotoras de biodiversidade.

3 REFERÊNCIAS

AGGARWAL, C. C. **Recommender Systems: The Textbook**. Cham: Springer International Publishing, 2016. DOI: <https://doi.org/10.1007/978-3-319-29659-3>.

BECK, J. et al. What's on the web? Assessing and aggregating biodiversity databases for systematic conservation planning. **PeerJ**, v. 2, p. e438, 2014. DOI: <https://doi.org/10.7717/peerj.438>.

BFG - The Brazil Flora Group. Growing knowledge: an overview of Seed Plant diversity in Brazil. **Rodriguésia**, v. 66, n. 4, p. 1085-1113, 2015. DOI: <https://doi.org/10.1590/2175-7860201566411>.

BRANCALION, P. H. S. et al. Global restoration opportunities in tropical rainforest landscapes. **Science Advances**, v. 5, n. 7, p. eaav3223, 2019. DOI: <https://doi.org/10.1126/sciadv.aav3223>.

BURKE, R. Hybrid Recommender Systems: Survey and Experiments. **User Modeling and User-Adapted Interaction**, v. 12, n. 4, p. 331-370, 2002. DOI: <https://doi.org/10.1023/A:1021240730564>.

CHAO, A. et al. Rarefaction and extrapolation with Hill numbers: a framework for sampling and estimation in species diversity studies. **Ecological Monographs**, v. 84, n. 1, p. 45-67, 2014. DOI: <https://doi.org/10.1890/13-0133.1>.

CHAZDON, R. L. **Second growth: the promise of tropical forest regeneration in an age of deforestation**. Chicago: University of Chicago Press, 2014.

CREMONESI, P.; KOREN, Y.; TURRIN, R. Performance of recommender algorithms on top-n recommendation tasks. In: ACM CONFERENCE ON RECOMMENDER SYSTEMS (RecSys), 4., 2010, Barcelona. **Proceedings...** New York: ACM, 2010. p. 39-46. DOI: <https://doi.org/10.1145/1864708.1864721>.

GBIF - GLOBAL BIODIVERSITY INFORMATION FACILITY. **GBIF Occurrence Data**. Copenhagen: GBIF, 2026. Disponível em: <https://www.gbif.org>. Acesso em: 26 set. 2026.

GRINNELL, J. The niche-relationships of the California Thrasher. **The Auk**, v. 34, n. 4, p. 427-433, 1917. DOI: <https://doi.org/10.2307/4072271>.

HU, Y.; KOREN, Y.; VOLINSKY, C. Collaborative Filtering for Implicit Feedback Datasets. In: IEEE INTERNATIONAL CONFERENCE ON DATA MINING (ICDM), 8., 2008, Pisa. **Proceedings...** Pisa: IEEE, 2008. p. 263-272. DOI: <https://doi.org/10.1109/ICDM.2008.22>.

HUTCHINSON, G. E. Concluding remarks. **Cold Spring Harbor Symposia on Quantitative Biology**, v. 22, p. 415-427, 1957. DOI: <https://doi.org/10.1101/SQB.1957.022.01.039>.

JÄRVELIN, K.; KEKÄLÄINEN, J. Cumulated gain-based evaluation of retrieval techniques. **ACM Transactions on Information Systems**, v. 20, n. 4, p. 422-446, 2002. DOI: <https://doi.org/10.1145/582415.582418>.

JBRJ - JARDIM BOTÂNICO DO RIO DE JANEIRO. **Flora e Funga do Brasil**. Rio de Janeiro: JBRJ, 2026. Disponível em: <http://floradobrasil.jbrj.gov.br/>. Acesso em: 26 set. 2026.

KOREN, Y.; BELL, R.; VOLINSKY, C. Matrix Factorization Techniques for Recommender Systems. **Computer**, v. 42, n. 8, p. 30-37, 2009. DOI: <https://doi.org/10.1109/MC.2009.263>.

LEGENDRE, P.; LEGENDRE, L. **Numerical Ecology**. 3. ed. Amsterdam: Elsevier, 2012.

LOPS, P.; DE GEMMIS, M.; SEMERARO, G. Content-based Recommender Systems: State of the Art and Trends. In: RICCI, F.; ROKACH, L.; SHAPIRA, B.; KANTOR, P. (org.). **Recommender Systems Handbook**. Boston: Springer, 2011. p. 73-105. DOI: https://doi.org/10.1007/978-0-387-85820-3_3.

MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. **Introduction to Information Retrieval**. Cambridge: Cambridge University Press, 2008. DOI: <https://doi.org/10.1017/CBO9780511809071>.

MEYER, C.; KREFT, H.; GURNEY, R.; JETZ, W. Global priorities for an effective information basis of biodiversity distributions. **Nature Communications**, v. 6, n. 8221, p. 1-8, 2015. DOI: <https://doi.org/10.1038/ncomms9221>.

RICCI, F.; ROKACH, L.; SHAPIRA, B. Introduction to Recommender Systems Handbook. In: RICCI, F.; ROKACH, L.; SHAPIRA, B.; KANTOR, P. (org.). **Recommender Systems Handbook**. Boston: Springer, 2011. p. 1-35. DOI: https://doi.org/10.1007/978-0-387-85820-3_1.

SALTON, G.; MCGILL, M. J. **Introduction to Modern Information Retrieval**. New York: McGraw-Hill, 1983.

SFB - SERVIÇO FLORESTAL BRASILEIRO. **Inventário Florestal Nacional: dados biofísicos e socioambientais**. Brasília: MAPA, 2025. Disponível em: <https://dados.florestal.gov.br/>. Acesso em: 26 set. 2026.

SOBERÓN, J. Grinnellian and Eltonian niches and geographic distributions of species. **Ecology Letters**, v. 10, n. 12, p. 1115-1123, 2007. DOI: <https://doi.org/10.1111/j.1461-0248.2007.01107.x>.

ZIEGLER, C.-N. et al. Improving recommendation lists through topic diversification. In: INTERNATIONAL CONFERENCE ON WORLD WIDE WEB (WWW), 14., 2005, Chiba. **Proceedings...** New York: ACM, 2005. p. 22-32. DOI: <https://doi.org/10.1145/1060745.1060754>.