UNIVERSIDADE PRESBITERIANA MACKENZIE

Fernanda Pauli de Oliveira – 10736757
Henrique Sarmento – 10738262
Milena Dias Gouveia – 10746134
Nicolly Falcão da Silva – 10746541

SISTEMA DE RECOMENDAÇÃO DE ESPÉCIES NATIVAS PARA REFLORESTAMENTO E ARBORIZAÇÃO URBANA (ODS 15)

Brasil
2026

Sumário

1 INTRODUÇÃO 4
1.1 Contexto 4
1.2 Motivação e justificativa 5
1.3 Objetivos 5
1.3.1 Objetivo Geral 5
1.3.2 Objetivos Específicos 5
1.3.3 Questão de Pesquisa 6
1.4 Definição da Base de Dados 6
1.4.1 Forma e Período de Coleta 7
1.4.2 Limitações dos Dados e Recorte Operacional 7
1.5 Visão Geral do Pipeline de Dados e Modelagem Híbrida 8
1.6 Cronograma de Execução 8
1.7 Repositório no GitHub 9
2 REFERENCIAL TEÓRICO 9
2.1 Teoria do Nicho Ecológico e Restauração Florestal Tropical 10
2.2 Filtragem Baseada em Conteúdo no Espaço Vetorial 10
2.3 Filtragem Colaborativa com Feedback Implícito e Fatoração Matricial 11
2.4 Taxonomia de Sistemas de Recomendação Híbridos em Cascata 13
2.5 Bioinformática, Vieses em Dados Abertos e Saneamento Taxonômico 15
2.6 Avaliação Além da Acurácia: Métricas de Ranking e Diversificação 15
3 METODOLOGIA 17
3.1 Definição do Problema e Objetivos 19
3.2 Coleta de Dados 20
3.3 Pré-processamento e Limpeza dos Dados 21
3.4 Divisão dos Dados 22
3.5 Seleção e Implementação do Algoritmo 23
3.6 Treinamento do Modelo 25
3.7 Avaliação do Desempenho 26
3.8 Otimização e Ajustes 28

3.9 Implantação e Monitoramento 30
3.10 Evolução da Etapa 2, Dificuldades Encontradas e Soluções Adotadas.....31
4 LIMITAÇÕES E AVISOS LEGAIS 32
4.1 Limitações das Fontes de Dados e da Malha Semi-Sintética 32
4.2 Limitações da Modelagem e Escopo da Arborização Urbana 33
4.3 Validade Experimental, Prevenção de Vazamento e Reprodutibilidade 33
4.4 Interpretação das Métricas Offline e do Pool Amostrado.....34
4.5 Uso Responsável e Governança na Prescrição Ambiental.....34
5 CONSIDERAÇÕES FINAIS 34
REFERÊNCIAS.....36

1 INTRODUÇÃO

1.1 Contexto

A degradação acelerada dos ecossistemas naturais e a perda contínua da cobertura vegetal nativa constituem ameaças críticas à estabilidade ecológica e climática global. Esse cenário demanda respostas sistemáticas e cientificamente orientadas, alinhando-se diretamente ao Objetivo de Desenvolvimento Sustentável 15 (ODS 15 — Vida Terrestre) estabelecido pela Organização das Nações Unidas na Agenda 2030 (ONU, 2015), cuja meta preconiza proteger, recuperar e promover o uso sustentável dos ecossistemas terrestres, deter a degradação do solo e conter a perda de biodiversidade.

Iniciativas práticas de reflorestamento rural e de expansão da arborização em ambientes urbanos enfrentam rotineiramente taxas expressivas de mortalidade precoce de mudas nos dois primeiros anos após o plantio (BRANCALION et al., 2019; CHAZDON, 2014). A literatura florestal demonstra que o insucesso do estabelecimento radicular decorre primordialmente da incompatibilidade entre as propriedades físico-químicas do terreno — tais como textura do solo, acidez ativa (pH), saturação por bases ($V\%$) e regime pluviométrico — e as tolerâncias fisiológicas intrínsecas das espécies selecionadas. Quando a prescrição botânica desconsidera esses condicionantes abióticos ou negligência as relações de facilitação ecológica e sucessão secundária entre comunidades vegetais, o plantio sucumbe a estresses edafoclimáticos e fitossanitários, gerando severo desperdício de recursos públicos e privados.

Nesse panorama, a Ciência de Dados e a Inteligência Artificial oferecem mecanismos para aproximar o conhecimento taxonômico e fitossociológico das decisões operacionais de manejo. A integração de repositórios biológicos abertos associada a algoritmos híbridos de recomendação permite converter catálogos botânicos e inventários florestais dispersos em prescrições ordenadas, explicáveis e funcionalmente diversificadas.

1.2 Motivação e justificativa

A relevância técnica, socioambiental e econômica deste projeto sustenta-se em três eixos principais:

- **Maximização da Sobrevivência Inicial de Mudas:** A filtragem estrita de compatibilidade edafoclimática reduz o risco de mortalidade precoce em campo e mitiga custos recorrentes de replantio corretivo;
- **Apoio Técnico Reprodutível à Gestão Ambiental:** Viveiros florestais, secretarias municipais de meio ambiente e projetos de restauração passam a dispor de um critério quantitativo transparente para priorizar matrizes nativas compatíveis com cada bioma e perfil pedológico;
- **Reconstituição de Serviços Ecossistêmicos e Resiliência Funcional:** A indução algorítmica de diversidade taxonômica e sucessional evita plantios homogêneos vulneráveis a pragas, favorecendo a infiltração hídrica, a ciclagem de nutrientes, a atenuação de ilhas de calor e a atração de polinizadores.

Ao traduzir parâmetros edafoclimáticos e padrões de coexistência florística em listas ranqueadas Top-K, o sistema atua como instrumento de suporte à decisão alinhado às metas nacionais de restauração de paisagens degradadas (STRASSBURG et al., 2020; CROUZEILLES et al., 2020).

1.3 Objetivos

1.3.1 Objetivo Geral

Desenvolver um sistema de recomendação híbrido de espécies vegetais nativas para apoio à restauração florestal e à arborização urbana, integrando atributos de adequabilidade edafoclimática (filtragem baseada em conteúdo) e padrões de coocorrência observados em unidades amostrais (filtragem colaborativa com feedback implícito).

1.3.2 Objetivos Específicos

Para alcançar o objetivo geral, definiram-se os seguintes objetivos específicos:

- Consolidar a partir dos repositórios públicos Flora e Funga do Brasil (JBRJ, 2026), Global Biodiversity Information Facility (GBIF, 2026) e diretrizes biofísicas do Inventário Florestal Nacional (SFB, 2025) uma base relacional harmonizada de espécies nativas, perfis edafoclimáticos e coocorrências amostrais;
- Implementar como etapa de saneamento bioinformático a resolução automatizada de sinonímias botânicas pelo vocabulário controlado do JBRJ, a subamostragem geográfica (*spatial thinning*) de ocorrências do GBIF e a imputação ecológica por conservadorismo filogenético;
- Estruturar por meio de uma arquitetura híbrida em cascata o acoplamento entre a Filtragem Baseada em Conteúdo com poda rígida (*hard filter*), a Fatoração Matricial via Mínimos Quadrados Alternados (*ALS*) acelerada em GPU (incluindo projeção ambiental para terrenos em *cold-start* estrito) e o reordenamento guloso de Diversidade Intra-Lista (ILD);
- Avaliar se o modelo híbrido proposto supera linhas de base univariadas (popularidade biogeográfica e conteúdo puro) em partição espacial estrita sem vazamento de informação, empregando as métricas $\mathrm{Precision@}K$, $\mathrm{Recall@}K$, $\mathrm{NDCG@}K$ e ILD.

1.3.3 Questão de Pesquisa

Como a combinação entre atributos edafoclimáticos das espécies nativas e padrões de coocorrência observados em inventários florestais pode aprimorar a acurácia de ordenamento, a explicabilidade e a diversidade funcional das recomendações Top-K para um sítio de plantio, em comparação com abordagens isoladas baseadas apenas em frequência biogeográfica ou similaridade ambiental?

1.4 Definição da Base de Dados

O pipeline de dados integra três fontes complementares de biodiversidade e atributos biofísicos:

1. **Flora e Funga do Brasil (Jardim Botânico do Rio de Janeiro — JBRJ):** Autoridade taxonômica oficial do território brasileiro (JBRJ, 2026), provendo

táxons aceitos, dicionário de sinonímias, famílias botânicas, formas de vida, substratos e distribuição nativa nos seis biomas continentais;

2. **Inventário Florestal Nacional (Serviço Florestal Brasileiro — SFB / MAPA):** Referencial metodológico de conglomerados espaciais compostos por quatro subunidades amostrais de 20 × 20 m (400 m²) associadas a descritores pedológicos e climáticos (SFB, 2025), estruturando a matriz esparsa de abundância parcela-espécie;
3. **Global Biodiversity Information Facility (GBIF):** Infraestrutura internacional de dados abertos de biodiversidade (GBIF, 2026), fornecendo registros georreferenciados de herbários e inventários de campo no território nacional para ancoragem biogeográfica.

1.4.1 Forma e Período de Coleta

A aquisição dos dados foi executada programaticamente em setembro de 2026 por meio do notebook `01_aquisicao_exploracao_limpeza_dados.ipynb`. Do portal IPT do JBRJ (JBRJ, 2026), realizou-se a ingestão integral do arquivo Darwin Core Archive (`lista_especies_flora_brasil.zip`, 20,4 MB, contendo 166.040 registros taxonômicos). Da API REST v1 do GBIF (GBIF, 2026), extraíram-se de modo concorrente 31.500 registros georreferenciados (`country=BR`, `hasCoordinate=true`, `kingdomKey=6`), priorizando coletas contemporâneas para refletir regimes climáticos atuais e nomenclatura revisada. Para a matriz parcela-espécie, estruturou-se uma malha sistemática de 600 conglomerados (2.400 parcelas) aderente ao desenho amostral do IFN (SFB, 2025), parametrizada sobre os táxons nativos reais extraídos do JBRJ e do GBIF.

1.4.2 Limitações dos Dados e Recorte Operacional

As bases de biodiversidade impõem quatro desafios centrais tratados na metodologia: (i) viés espacial de amostragem (*roadside bias*) nas ocorrências abertas do GBIF; (ii) fragmentação de contagens por sinonímias taxonômicas históricas; (iii) elevada esparsidade matricial (99,00% de células nulas na matriz parcela-espécie), na qual zeros representam ausências não observadas e não incompatibilidade biológica comprovada; e (iv) disponibilidade assimétrica de microdados pedológicos em inventários públicos.

Quanto ao escopo de aplicação anunciado no título do projeto (mantido em continuidade institucional com as Etapas 1 e 2), esclarece-se que a **validação quantitativa empírica desta Etapa 3 concentra-se em parcelas de restauração florestal**. As restrições específicas de infraestrutura de **arborização urbana** — tais como porte máximo sob fiação aérea, largura efetiva de calçada, ausência de frutos grandes em vias carroçáveis e não agressividade do sistema radicular — encontram-se arquiteturalmente previstas como predicados booleanos extensíveis no filtro rígido (*hard filter*) da Fase 1 (Seção 3.5), sem que se reivindique validação empírica em inventários viários municipais neste ciclo.

1.5 Visão Geral do Pipeline de Dados e Modelagem Híbrida

O fluxo metodológico implementado articula seis estágios sequenciais: (1) ingestão automatizada DwC-A/REST e estruturação da malha amostral; (2) resolução taxonômica via dicionário de 66.067 sinônimos do JBRJ e *spatial thinning* em grade de 0,05°; (3) engenharia de atributos edafoclimáticos e partição espacial estrita por conglomerados (70% treino, 15% validação e 15% teste cego); (4) Fase 1 — filtragem de conteúdo com poda rígida biogeográfica e edáfica; (5) Fase 2 — fatoração matricial implícita via ALS em GPU com inferência indutiva *fold-in* e contorno de *cold-start* estrito via vizinhança ambiental; e (6) reordenamento guloso para maximização conjunta de relevância e Diversidade Intra-Lista (ILD).

1.6 Cronograma de Execução

O planejamento executivo do projeto ao longo do segundo semestre letivo de 2026, discriminando o encadeamento das entregas e o status consolidado ao término da Etapa 3, é apresentado no Quadro 1 (mantido em sincronia com a planilha `Cronograma_ODS15_Segundo_Semestre_2026.xlsx` do repositório).

Quadro 1 – Cronograma atualizado de execução do projeto no segundo semestre de 2026.

Período	Atividade Técnica / Acadêmica	Situação Atual	Entregável Verificável
01–15 jul. 2026	Definição do problema, objetivos e recorte do ODS 15	**Concluída**	Escopo e questão de pesquisa (Etapa 1).
16–31 jul. 2026	Fundamentação teórica e seleção das fontes públicas	**Concluída**	Referencial teórico JBRJ, IFN e GBIF.
01–15 ago. 2026	Prova de conceito preliminar (PoC) em escala reduzida	**Concluída**	Protótipo inicial e diagnóstico (Etapa 2).
16–31 ago. 2026	Ingestão massiva DwC-A JBRJ e API REST GBIF	**Concluída**	Notebook 01 e artefatos limpos em disco.
01–20 set. 2026	Saneamento taxonômico, spatial thinning e malha IFN	**Concluída**	Catálogo mestre (18.692 spp.) e 2.400 parcelas.
21 set.–10 out. 2026	Refatoração do pipeline ALS em GPU, k-NN e ILD	**Concluída**	Notebook 02 executado sem data leakage.
11–29 out. 2026	Validação cega Top-K, análise de sensibilidade e relatório	**Concluída**	Relatório ABNT da Etapa 3 e JSON oficial.
01–30 nov. 2026	Consolidação visual, validação especialista e defesa final	Em andamento	Apresentação final da Etapa 4.

Fonte: Elaborado pelos autores (2026).

1.7 Repositório no GitHub

Os notebooks interativos autocontidos, scripts de geração diagramática, artefatos processados e documentação técnica são versionados no repositório público oficial do grupo: **https://github.com/henri-sarmento/ProjetoAplicado3**.

2 REFERENCIAL TEÓRICO

A fundamentação teórica deste trabalho articula postulados clássicos da ecologia vegetal e da restauração florestal tropical com formulações matemáticas de sistemas de recomendação e recuperação de informação. Essa convergência permite traduzir conceitos biológicos — nicho fundamental, nicho realizado, sucessão secundária e vieses de inventário — em operadores algébricos tratáveis computacionalmente.

2.1 Teoria do Nicho Ecológico e Restauração Florestal Tropical

A distribuição geográfica e a persistência demográfica de espécies vegetais são regidas pela Teoria do Nicho Ecológico. Introduzido por Grinnell (1917) sob a ótica das restrições físicas de habitat, o conceito foi formalizado matematicamente por Hutchinson (1957) como um hipervolume n-dimensional definido por eixos ambientais e recursos nos quais uma população mantém taxa líquida de reprodução positiva.

Hutchinson (1957) distingue dois domínios complementares: (1) o **Nicho Fundamental (**N_F**)**, que compreende o envelope fisiológico completo de condições abióticas (pH, fertilidade, textura edáfica, temperatura e precipitação) toleráveis pela espécie na ausência de competidores ou patógenos; e (2) o **Nicho Realizado (**N_R**)**, subconjunto efetivamente ocupado na natureza após a atuação de interações bióticas de competição, facilitação e limitação de dispersão. Soberón (2007) sintetizou essa interação no diagrama BAM (Biótica B, Abiótica A e Movimentação M), demonstrando que a ocorrência estável exige compatibilidade simultânea nos três eixos.

Em restauração ecológica tropical, a mortalidade de mudas nos primeiros 24 meses constitui o principal gargalo operacional (BRANCALION et al., 2019; CHAZDON, 2014). Evidências empíricas recentes de Stubblefield et al. (2023) comprovam que modelos preditivos alimentados por atributos edáficos e pluviométricos antecipam falhas de estabelecimento de mudas arbóreas, ao passo que o planejamento espacial baseado em adequabilidade ecológica reduz em até 40% os custos de restauração em larga escala (STRASSBURG et al., 2020; CROUZEILLES et al., 2020).

2.2 Filtragem Baseada em Conteúdo no Espaço Vetorial

Sistemas de Filtragem Baseada em Conteúdo (*Content-Based Filtering* — CBF) recomendam itens cujos atributos descritivos apresentam alinhamento estrutural com o perfil de restrições da entidade alvo (RICCI; ROKACH; SHAPIRA, 2011; LOPS; DE GEMMIS; SEMERARO, 2011). Apoiando-se no Modelo de Espaço Vetorial de Salton e McGill (1983) sistematizado por Aggarwal (2016), o sítio de plantio e cada espécie

nativa são representados como vetores $\boldsymbol{u} \in \mathbb{R}^d$ e $\boldsymbol{i} \in \mathbb{R}^d$ em um espaço comum de d descritores codificados e normalizados.

A aderência direcional entre o perfil ambiental do terreno $\boldsymbol{u}$ e o envelope fisiológico da espécie $\boldsymbol{i}$ é mensurada pela **Similaridade do Cosseno** (SALTON; MCGILL, 1983; RICCI; ROKACH; SHAPIRA, 2011), expressa pela Equação (1):

$$\text{Simil}(\boldsymbol{u}, \boldsymbol{i}) = \frac{\boldsymbol{u} \cdot \boldsymbol{i}}{\| \boldsymbol{u} \| \| \boldsymbol{i} \|} = \frac{\sum_{k=1}^{d} u_k \cdot i_k}{\sqrt{\sum_{k=1}^{d} u_k^2} \sqrt{\sum_{k=1}^{d} i_k^2}} \qquad (1)$$

No domínio de atributos não-negativos normalizados, obtém-se $\text{Simil}(\boldsymbol{u}, \boldsymbol{i}) \in [0, 1]$. Conforme destacam Lops, de Gemmis e Semeraro (2011), modelos CBF operam com robustez sobre itens recém-catalogados (*item cold-start*), permitindo avaliar espécies raras dotadas de ficha botânica. Todavia, Aggarwal (2016) demonstra que o CBF isolado incorre em *overspecialization* (superespecialização): ao depender apenas de atributos individuais estáticos, o modelo tende a recomendar táxons funcionalmente redundantes e mostra-se cego às sinergias fitossociológicas do nicho realizado.

2.3 Filtragem Colaborativa com Feedback Implícito e Fatoração Matricial

Para capturar padrões empíricos de coexistência comunitária e sucessão ecológica observados em inventários florestais (LEGENDRE; LEGENDRE, 2012; CHAZDON, 2014), recorre-se à **Filtragem Colaborativa** (*Collaborative Filtering* — CF) por fatores latentes (KOREN; BELL; VOLINSKY, 2009). Diferentemente de plataformas comerciais com avaliações explícitas, levantamentos fitossociológicos registram apenas contagens de abundância viva $r_{ui} \geq 0$, caracterizando um regime estrito de **Feedback Implícito** (HU; KOREN; VOLINSKY, 2008).

Em matrizes implícitas, $r_{ui} = 0$ não significa incompatibilidade ecológica comprovada, mas ausência de observação amostral (limitação de dispersão, histórico

de perturbação ou cobertura finita da parcela), enquanto $r_{ui} > 0$ constitui evidência positiva de estabelecimento. Hu, Koren e Volinsky (2008) decompõem r_{ui} na variável de **Preferência Binária** ($p_{ui} \in \{0, 1\}$) e no peso de **Confiança Ponderada** (c_{ui}), definidos pelas Equações (2) e (3):

$$p_{ui} = \begin{cases} 1, & \text{se } r_{ui} > 0 \\ 0, & \text{se } r_{ui} = 0 \end{cases} \qquad (2)$$

$$c_{ui} = 1 + \alpha \cdot r_{ui} \qquad (3)$$

em que α ($\alpha > 0$) regula a taxa de incremento da confiança conforme cresce a abundância de indivíduos vivos na parcela. Cada unidade amostral u e cada espécie i são associadas a vetores latentes $\boldsymbol{x}_u, \boldsymbol{y}_i \in \mathbb{R}^f$ de baixa dimensão ($f \ll \min(|\mathcal{U}|, |\mathcal{I}|)$), cuja afinidade é estimada pelo produto interno da Equação (4):

$$\hat{p}_{ui} = \boldsymbol{x}_u^T \boldsymbol{y}_i \qquad (4)$$

Os fatores latentes são estimados minimizando-se a função de perda quadrática ponderada com regularização Tikhonov L_2 por meio do algoritmo de **Mínimos Quadrados Alternados** (*Alternating Least Squares* — ALS), explicitada com seus limites formais de somatório na Equação (5):

$$\mathcal{L}_{\text{ALS}} = \sum_{u=1}^{|\mathcal{U}|} \sum_{i=1}^{|\mathcal{I}|} c_{ui}(p_{ui} - \boldsymbol{x}_u^T \boldsymbol{y}_i)^2 + \lambda \left(\sum_{u=1}^{|\mathcal{U}|} \| \boldsymbol{x}_u \|_2^2 + \sum_{i=1}^{|\mathcal{I}|} \| \boldsymbol{y}_i \|_2^2 \right) \qquad (5)$$

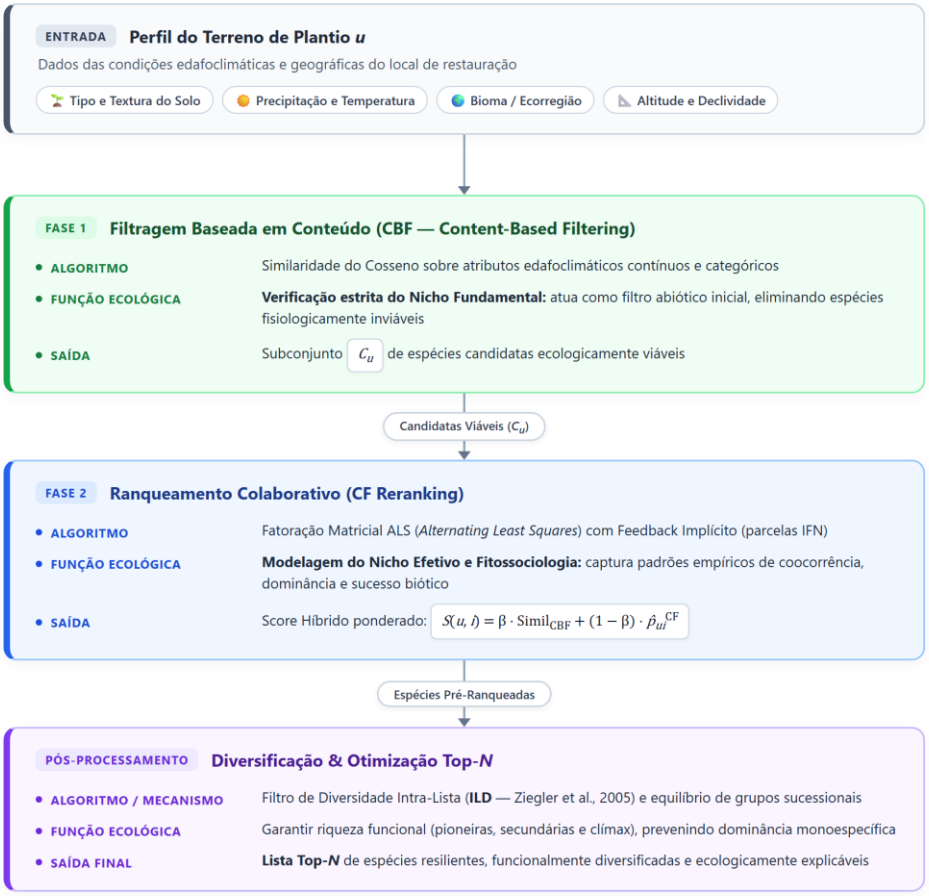
onde $\mathcal{U}$ e $\mathcal{I}$ denotam respectivamente os conjuntos de parcelas de treino e de espécies catalogadas, e λ controla a penalização L_2 contra sobreajuste. Ao fixar

alternadamente os fatores de espécies e de parcelas, cada subproblema torna-se quadrático estritamente convexo e paralelizável em GPU. Rendle et al. (2020) demonstraram que fatorações matriciais clássicas devidamente calibradas superam ou igualam arquiteturas neurais complexas como *Neural Collaborative Filtering* (HE et al., 2017) em benchmarks de feedback implícito, aliando estabilidade numérica e eficiência computacional.

2.4 Taxonomia de Sistemas de Recomendação Híbridos em Cascata

Diante das limitações complementares entre CBF e CF, a taxonomia clássica de Burke (2002) sistematiza os **Sistemas Híbridos em Cascata (*Cascade Hybrid Recommenders*)** (RICCI; ROKACH; SHAPIRA, 2011; AGGARWAL, 2016). Conforme esquematizado conceitualmente na Figura 1, o primeiro estágio aplica restrições determinísticas e similaridade de conteúdo sobre o nicho fundamental para eliminar espécies fisiologicamente inviáveis, produzindo um subconjunto qualificado $\mathcal{C}_u$; o segundo estágio refina a ordenação dessas candidatas por afinidade colaborativa latente.

Figura 1 – Arquitetura conceitual do recomendador híbrido em duas fases para restauração florestal.



Fonte: Elaborado pelos autores (2026).

A combinação dos sinais normalizados de adequabilidade de conteúdo $s_{\text{CBF}}(u,i)$ e de coocorrência colaborativa $s_{\text{CF}}(u,i)$ para cada candidata $i \in \mathcal{C}_u$ é expressa na forma geral pela Equação (6):

$$S(u,i) = \beta \cdot s_{\text{CBF}}(u,i) + (1-\beta) \cdot s_{\text{CF}}(u,i) \qquad (6)$$

em que $\beta \in [0,1]$ pondera explicitamente o compromisso entre fidelidade abiótica ao sítio e sinergia fitossociológica empírica.

2.5 Bioinformática, Vieses em Dados Abertos e Saneamento Taxonômico

A modelagem quantitativa sobre repositórios públicos de biodiversidade requer mitigação rigorosa de dois artefatos sistemáticos:

1. **Viés de Amostragem Espacial (*Spatial Sampling Bias*):** Bases colaborativas globais exibem forte aglomeração de coletas ao longo de malhas viárias, centros de pesquisa e fragmentos periurbanos (BECK et al., 2014; MEYER et al., 2015). Sem correção, o modelo aprende gradientes de acessibilidade antrópica em vez de limites ecológicos. A higienização automatizada de coordenadas (ZIZKA et al., 2019) combinada à **subamostragem espacial em grade (*spatial thinning*)** (STEEN et al., 2021) reduz a autocorrelação espacial espúria preservando a amplitude ambiental dos táxons;
2. **Sinonímia Nomenclatural e Fragmentação Matricial:** Revisões filogenéticas contínuas na flora neotropical (BFG, 2015) fazem com que uma mesma entidade biológica figure sob múltiplos binômios históricos em diferentes inventários. A reconciliação contra um vocabulário controlado oficial (JBRJ, 2026) é indispensável para impedir a diluição artificial dos vetores na matriz de coocorrência.

2.6 Avaliação Além da Acurácia: Métricas de Ranking e Diversificação

A avaliação *offline* de sistemas de recomendação Top-K prioriza a utilidade das posições superiores da lista prescrita $L_K(u) = \langle i_{(1)}, i_{(2)}, \dots, i_{(K)} \rangle$ frente ao conjunto de itens relevantes ocultos T_u da unidade avaliada (CREMONESI; KOREN; TURRIN, 2010; RICCI; ROKACH; SHAPIRA, 2011). Adotam-se quatro métricas complementares:

- **Precisão e Revocação em K ($\mathrm{Precision@}K$ e $\mathrm{Recall@}K$):** Fundamentadas na recuperação de informação clássica (MANNING; RAGHAVAN; SCHÜTZE, 2008), mensuram respectivamente a fração de acertos entre as K espécies recomendadas e a proporção do gabarito T_u recuperada até o corte K, conforme as Equações (7) e (8):

$$\text{Precision@}K = \frac{|\, L_K(u) \cap T_u \,|}{K} \qquad (7)$$

$$\text{Recall@}K = \frac{|\, L_K(u) \cap T_u \,|}{|\, T_u \,|} \qquad (8)$$

- **Ganho Cumulativo Descontado Normalizado ($\text{NDCG@}K$):** Proposto por Järvelin e Kekäläinen (2002), penaliza logaritmicamente acertos que ocorrem em posições tardias do ranking r (r = 1, …, K). Definindo-se a relevância binária $\text{rel}_r \in \{0, 1\}$ para indicar se a espécie alocada na posição r pertence a T_u, o ganho descontado ($\text{DCG@}K$) e sua forma normalizada pelo ordenamento ideal ($\text{IDCG@}K$) são dados pelas Equações (9) e (10):

$$\text{DCG@}K = \sum_{r=1}^{K} \frac{2^{\text{rel}_r} - 1}{\log_2(r + 1)} \qquad (9)$$

$$\text{NDCG@}K = \frac{\text{DCG@}K}{\text{IDCG@}K} \in [0, 1] \qquad (10)$$

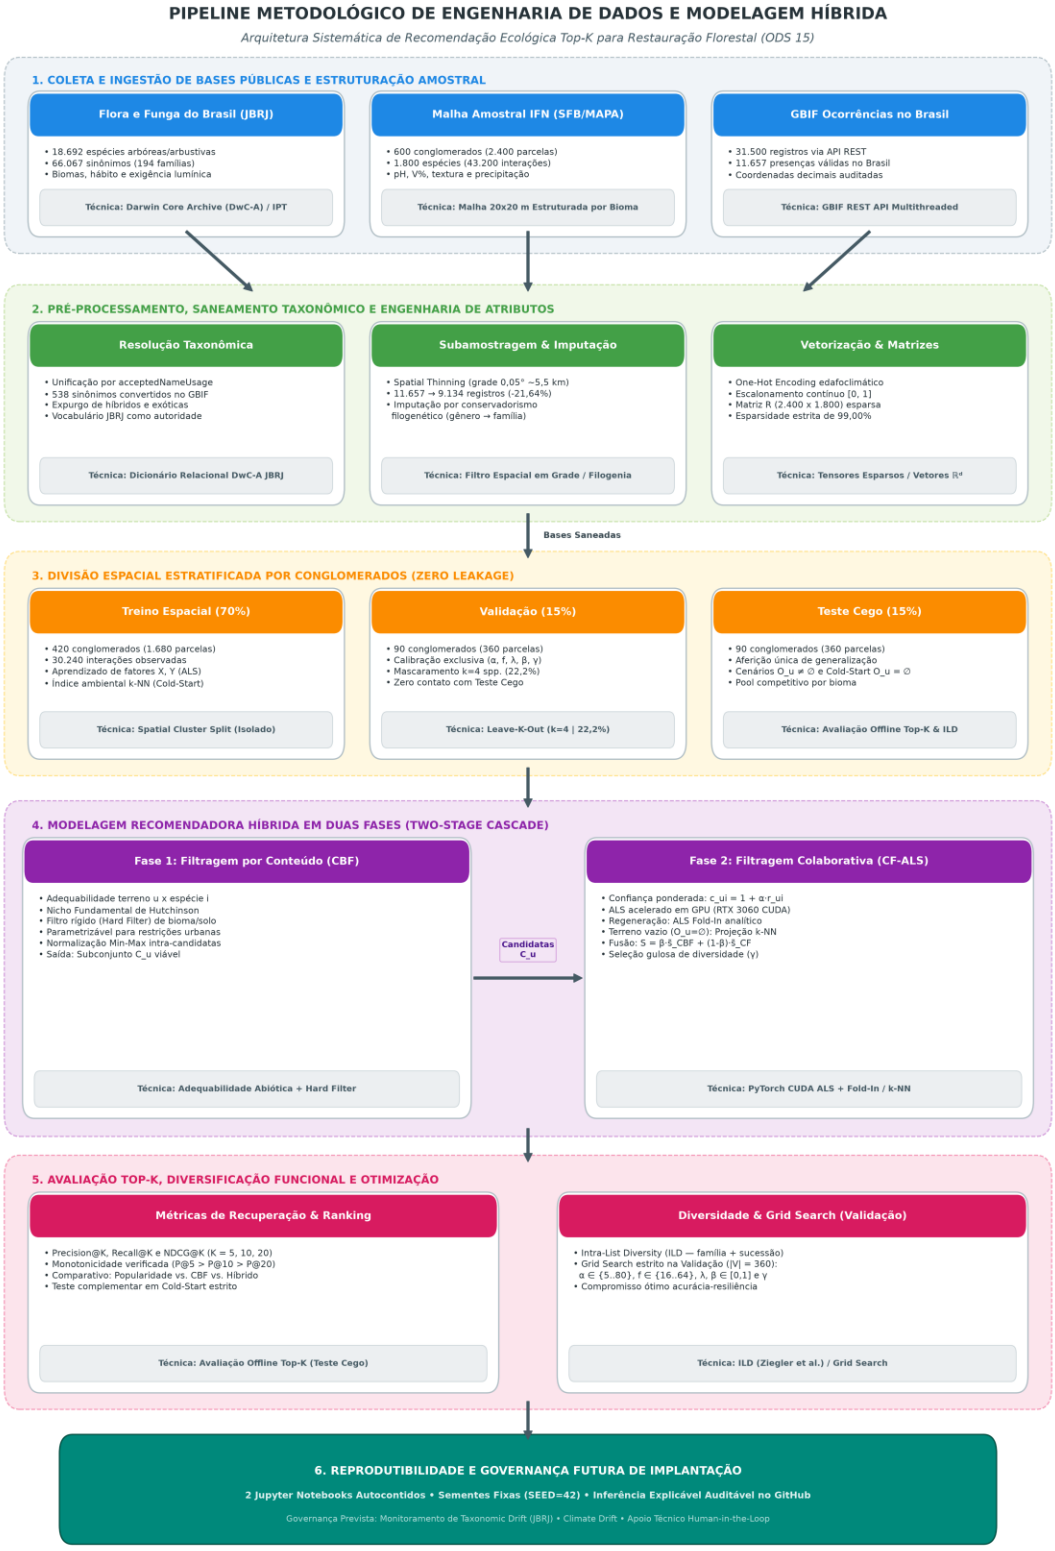
- **Diversidade Intra-Lista (ILD):** Em restauração florestal, listas de alta precisão, porém restritas a um único gênero ou grupo sucessional comprometem a estratificação de dossel e a resistência fitossanitária (CHAZDON, 2014; BRANCALION et al., 2019). A métrica ILD, introduzida por Ziegler et al. (2005) e consolidada por Kunaver e Požrl (2017), quantifica a dissimilaridade par-a-par média $d(i, j) \in [0, 1]$ entre as K espécies recomendadas, conforme a Equação (11):

$$\text{ILD}(L_K) = \frac{2}{K(K - 1)} \sum_{r=1}^{K-1} \sum_{s=r+1}^{K} d\left(i_{(r)}, i_{(s)}\right) \qquad (11)$$

3 METODOLOGIA

Nesta seção apresenta-se a engenharia metodológica implementada, detalhando a aquisição de dados, o saneamento bioinformático, o particionamento espacial livre de vazamento, a formulação matemática operacional dos algoritmos e os experimentos comparativos executados em GPU. A arquitetura de ponta a ponta do pipeline desenvolvido é sintetizada na Figura 2.

Figura 2 – Pipeline metodológico integrado de engenharia de dados, modelagem híbrida em GPU e validação espacial.



Fonte: Elaborado pelos autores (2026).

Conforme ilustrado na Figura 2, todas as transformações — desde a reconciliação taxonômica sobre o catálogo oficial do JBRJ até a inferência Top-K com diversificação ecológica — encontram-se encapsuladas de forma reprodutível e sequencial nos dois notebooks oficiais do projeto.

3.1 Definição do Problema e Objetivos

Formula-se o problema de prescrição florística como uma tarefa de ranqueamento personalizado Top-K condicionada por restrições ecológicas estritas. Dados o vetor ambiental do sítio de intervenção $\boldsymbol{e}_u$ e o conjunto (eventualmente vazio) de espécies remanescentes já observadas na área O_u, busca-se produzir uma lista ordenada $L_K(u) = \langle i_{(1)}, i_{(2)}, \dots, i_{(K)} \rangle$ de K espécies nativas que maximize conjuntamente a viabilidade fisiológica, a afinidade fitossociológica e a diversidade funcional.

Os elementos da modelagem realizada compreendem:

- **Espaço de Unidades Amostrais ($\mathcal{U}$):** Malha composta por 600 conglomerados espaciais totalizando $|\mathcal{U}| = 2.400$ parcelas padronizadas de 20 × 20 m (400 m²), caracterizadas por bioma, coordenadas geográficas, pH em $\mathrm{H_2O}$, saturação por bases ($V\%$), classe textural do solo e precipitação anual acumulada;
- **Espaço de Espécies Candidatas ($\mathcal{I}$):** Vocabulário ativo de $|\mathcal{I}| = 1.800$ espécies arbóreas e arbustivas nativas com coocorrências registradas na malha amostral, extraídas do universo curado de 18.692 espécies nativas aceitas pelo JBRJ;
- **Matriz Esparsa de Abundância Implícita ($\boldsymbol{R} \in \mathbb{R}^{|\mathcal{U}|\times|\mathcal{I}|}$):** Matriz contendo 43.200 interações positivas ($r_{ui} > 0$) distribuídas nas dimensões 2.400 × 1.800, resultando em esparsidade exata de 99,00% (densidade de 1,00%), convertida em preferências p_{ui} e pesos de confiança $c_{ui} = 1 + \alpha r_{ui}$ segundo Hu, Koren e Volinsky (2008).

3.2 Coleta de Dados

A coleta e estruturação dos dados no notebook `01_aquisicao_exploracao_limpeza_dados.ipynb` combinaram extrações públicas reais e estruturação amostral controlada:

1. **Catálogo Taxonômico Real — Flora e Funga do Brasil (JBRJ, 2026):** Download automatizado do pacote Darwin Core Archive oficial (`lista_especies_flora_brasil.zip`, 20,4 MB), processando os arquivos `taxon.txt` (166.040 registros totais), `distribution.txt` e `speciesprofile.txt`. Após filtragem para espécies nativas aceitas de hábito arbóreo, arbustivo e arborescente nos seis biomas brasileiros, consolidaram-se **18.692 espécies aceitas** distribuídas em **194 famílias** e **1.699 gêneros**, além de um dicionário relacional com **66.067 sinônimos botânicos**;
2. **Ocorrências Georreferenciadas Reais — GBIF (GBIF, 2026):** Coleta concorrente via API REST oficial (`https://api.gbif.org/v1/occurrence/search`) de **31.500 registros brutos** em território brasileiro. Após validação de coordenadas dentro dos limites continentais do país, descarte de registros sem epíteto específico e reconciliação nomenclatural contra o dicionário do JBRJ (que converteu 538 binômios sinônimos para nomes válidos), obtiveram-se **11.657 ocorrências georreferenciadas válidas**;
3. **Malha Estruturada de Parcelas Aderente ao IFN (SFB, 2025):** Em virtude da disponibilização heterogênea de microdados brutos georreferenciados em nível de subunidade e laudo físico-químico unificado entre ciclos estaduais do IFN, estruturou-se com transparência metodológica uma malha semi-sintética realista seguindo rigorosamente o protocolo amostral do SFB (600 conglomerados × 4 parcelas de 400 m² = **2.400 parcelas** e **43.200 interações**, semente fixa `42`). Os pools florísticos, guildas sucessionais e envelopes climáticos e edáficos (pH de 4,2 a 7,2; $V\%$; textura arenosa, média, argilosa e muito argilosa; precipitação de 450 a 2.800 mm/ano) foram parametrizados diretamente sobre os táxons nativos reais do JBRJ e ocorrências do GBIF em cada bioma.

3.3 Pré-processamento e Limpeza dos Dados

Quatro transformações sequenciais garantiram a integridade estatística e botânica dos artefatos:

- **Harmonização Taxonômica e Eliminação de Exóticas:** Todos os nomes científicos foram confrontados com o campo `acceptedNameUsage` do JBRJ, unificando variantes ortográficas e basiônimos (como *Schinus terebinthifolius* para *Schinus terebinthifolia* e *Tabebuia heptaphylla* para *Handroanthus heptaphyllus*) e removendo táxons exóticos invasores (como *Leucaena leucocephala* e *Pinus elliottii*). Contagens duplicadas geradas pela fusão de sinônimos em uma mesma parcela foram agregadas por soma de abundância viva;
- **Subamostragem Espacial (*Spatial Thinning*) no GBIF:** Aplicou-se filtragem em grade regular de 0,05° × 0,05° (aproximadamente 5,5 km × 5,5 km no equador), retendo-se no máximo um registro por espécie por célula (STEEN et al., 2021). O procedimento reduziu o conjunto validado do GBIF de **11.657 para 9.134 registros**, eliminando **21,64%** de observações espacialmente redundantes concentradas em eixos rodoviários e periurbanos;
- **Imputação por Conservadorismo Filogenético:** Atributos edáficos contínuos ausentes em espécies subamostradas foram imputados hierarquicamente pela média empírica do gênero botânico correspondente e, na ausência deste, pela média da família no respectivo bioma;
- **Codificação Vetorial Padronizada:** Descritores categóricos (bioma, textura edáfica e grupo sucessional) foram convertidos via *One-Hot Encoding*, variáveis contínuas (pH, $V\%$ e precipitação anual) foram escalonadas linearmente para $[0, 1]$ ajustando-se os parâmetros de normalização exclusivamente sobre a partição de treinamento, e as interações positivas foram indexadas em tensores esparsos na memória da GPU.

3.4 Divisão dos Dados

Parcelas pertencentes a um mesmo conglomerado do IFN distam poucas dezenas de metros entre si, compartilhando pedologia, microclima e chuva de propágulos. Um particionamento aleatório simples em nível de parcela ou de interação alocaria subunidades vizinhas simultaneamente no treino e no teste, introduzindo vazamento severo de informação (*spatial data leakage*).

Para blindar a avaliação experimental, implementou-se no notebook `02_pipeline_modelagem_recomendador.ipynb` a **Divisão Espacial Estrita por Conglomerados (*Spatial Cluster Split*)**, com verificação programática de interseção nula entre os três subconjuntos:

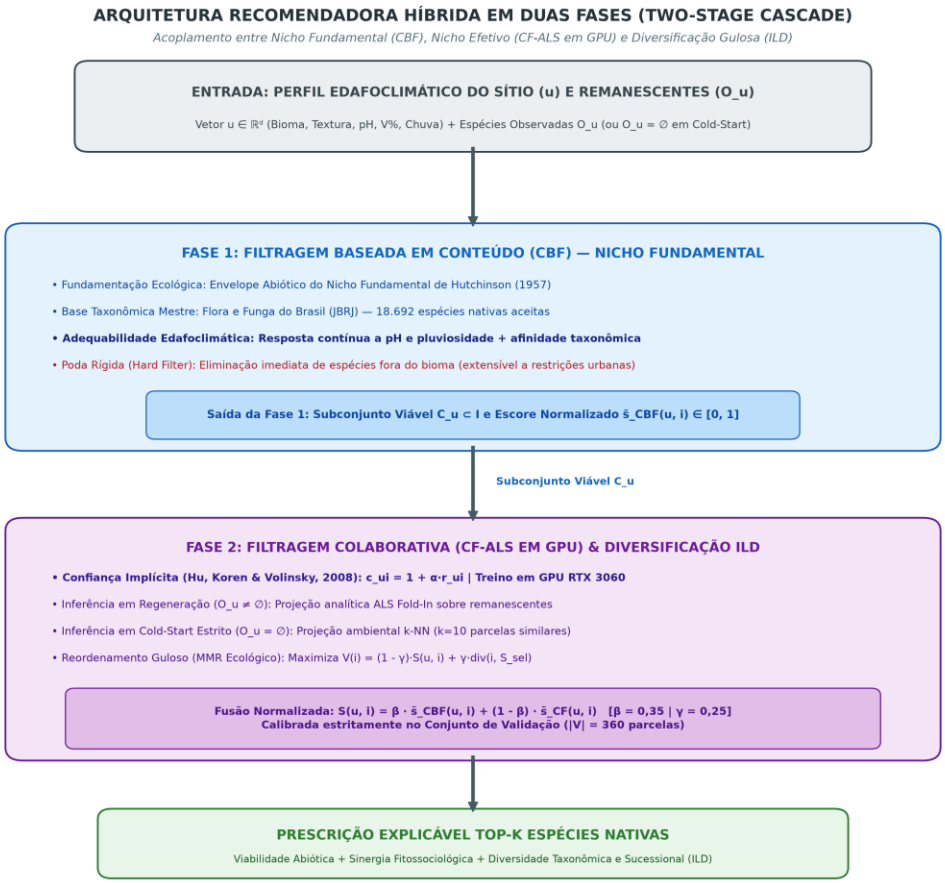
- **Conjunto de Treinamento (70%):** 420 conglomerados (1680 parcelas físicas e 30.240 interações positivas), empregados na estimação dos fatores latentes $\boldsymbol{Y}$, dos perfis de popularidade biogeográfica e da vizinhança ambiental de referência;
- **Conjunto de Validação Isolado (15%):** 90 conglomerados ($|\mathcal{V}| = 360$ parcelas e 6.480 interações), utilizados exclusivamente na busca em grade (*Grid Search*) e na calibração de sensibilidade dos hiperparâmetros ($\alpha, f, \lambda, \beta, \gamma$);
- **Conjunto de Teste Cego (15%):** 90 conglomerados ($|\mathcal{U}_{\text{teste}}| = 360$ parcelas e 6.480 interações), mantidos integralmente isolados até a aferição final das métricas reportadas na Tabela 1.

Em cada parcela avaliada (18 espécies nativas observadas), aplicou-se o protocolo *leave-k-out* com semente determinística por unidade: $k = 4$ espécies (22,2%) foram mascaradas para compor o gabarito oculto T_u, restando 14 espécies visíveis em O_u para simular o enriquecimento de fragmentos em regeneração. Seguindo o protocolo de amostragem negativa controlada de Cremonesi, Koren e Turrin (2010), os modelos ordenam um *pool* competitivo de 100 espécies candidatas nativas do mesmo bioma (4 alvos verdadeiros em T_u + 96 espécies negativas não observadas na parcela). Adicionalmente, avaliou-se o regime extremo de ***Cold-Start* Estrito ($O_u = \emptyset$)**, no qual 100% da flora local é ocultada e o sistema recebe unicamente o laudo abiótico do terreno degradado.

3.5 Seleção e Implementação do Algoritmo

Implementou-se uma **Arquitetura Híbrida em Cascata de Dois Estágios com Pós-Processamento de Diversificação Ecológica**, cujos fluxos matemáticos operacionais — incluindo tanto o enriquecimento com espécies remanescentes quanto o *cold-start* estrito — são detalhados na Figura 3.

Figura 3 – Arquitetura operacional detalhada do recomendador híbrido em duas fases com suporte a cold-start e diversificação ILD.



Fonte: Elaborado pelos autores (2026).

Na **Fase 1 (Filtragem de Conteúdo e Poda Rígida)**, aplica-se inicialmente o filtro eliminatório (*hard filter*) de Hutchinson (1957): apenas espécies nativas do bioma do sítio e cujas tolerâncias de acidez edáfica e regime hídrico não violem os limites

críticos do terreno integram o conjunto viável $\mathcal{C}_u \subset \mathcal{I}$ ($|\mathcal{C}_u| \ll |\mathcal{I}|$). Conforme delineado na Seção 1.4.2, em cenários futuros de arborização viária urbana, predicados booleanos adicionais (porte máximo sob rede elétrica, largura mínima de passeio e arquitetura radicular não intrusiva) acoplam-se diretamente a esse operador de poda sem alterar os estágios subsequentes. Para cada $i \in \mathcal{C}_u$, o escore operacional de conteúdo combina o cosseno abiótico entre $\boldsymbol{e}_u$ e $\boldsymbol{e}_i$ à afinidade filogenética familiar $\bar{\phi}_{\text{fam}}(i, O_u)$ (com ω_{amb} = 0,70 quando $O_u \neq \emptyset$ e ω_{amb} = 1,00 quando $O_u = \emptyset$), conforme a Equação (12):

$$s_{\text{CBF}}(u,i) = \mathbb{I}(i \in \mathcal{C}_u) \cdot \left[\omega_{\text{amb}} \frac{\boldsymbol{e}_u \cdot \boldsymbol{e}_i}{\| \boldsymbol{e}_u \| \| \boldsymbol{e}_i \|} + (1 - \omega_{\text{amb}})\bar{\phi}_{\text{fam}}(i, O_u)\right] \tag{12}$$

Na **Fase 2 (Fatoração Colaborativa Implícita em GPU e Contorno de *Cold-Start*)**, os fatores latentes das espécies $\boldsymbol{Y}$ são aprendidos exclusivamente sobre as 1.680 parcelas de treinamento via ALS (HU; KOREN; VOLINSKY, 2008). Durante a inferência sobre uma parcela externa u de validação ou teste (sem qualquer retreinamento da matriz global), distinguem-se dois regimes analíticos:

- **Regime de Enriquecimento Florestal ($O_u \neq \emptyset$):** O vetor latente $\boldsymbol{x}_u$ é obtido em forma fechada por projeção indutiva *ALS Fold-In* ponderada pelas abundâncias observadas em O_u, conforme a Equação (13):

$$\boldsymbol{x}_u = \left(\boldsymbol{Y}^T\boldsymbol{Y} + \boldsymbol{Y}_{O_u}{}^T \text{diag}(\alpha \boldsymbol{r}_{u,O_u})\boldsymbol{Y}_{O_u} + \lambda \boldsymbol{I}_f\right)^{-1} \boldsymbol{Y}_{O_u}{}^T (\mathbf{1} + \alpha \boldsymbol{r}_{u,O_u}) \tag{13}$$

- **Regime de *Cold-Start* Estrito em Áreas Degradadas ($O_u = \emptyset$):** Na ausência total de indivíduos arbóreos remanescentes, identifica-se no espaço abiótico padronizado o conjunto $\mathcal{N}_k(u)$ das $k = 15$ parcelas de treinamento ambientalmente mais próximas dentro do mesmo bioma e estima-se o perfil latente por interpolação ponderada pela similaridade ambiental w_{uv}, conforme a Equação (14):

$$\boldsymbol{x}_u^{\text{cold}} = \frac{\sum_{v \in \mathcal{N}_k(u)} w_{uv} \boldsymbol{x}_v}{\sum_{v \in \mathcal{N}_k(u)} w_{uv} + \varepsilon} \qquad (14)$$

Como o cosseno ambiental $s_{\text{CBF}}(u,i)$ e o produto interno latente $s_{\text{CF}}(u,i)$ operam em escalas numéricas e distribuições distintas, ambos os vetores passam por **normalização *Min-Max* intra-candidatas** sobre $\mathcal{C}_u$ (com constante de estabilidade ε = 10^{-9}) antes da fusão linear governada por $\beta \in [0,1]$, conforme a Equação (15):

$$\tilde{s}_m(u,i) = \frac{s_m(u,i) - \min_{j \in \mathcal{C}_u} s_m(u,j)}{\max_{j \in \mathcal{C}_u} s_m(u,j) - \min_{j \in \mathcal{C}_u} s_m(u,j) + \varepsilon}, \; S(u,i) \qquad (15)$$

$$= \beta \tilde{s}_{\text{CBF}}(u,i) + (1-\beta)\tilde{s}_{\text{CF}}(u,i)$$

Finalmente, para evitar listas monopolizadas por um único gênero ou estrato ecológico, aplica-se um **reordenamento guloso iterativo** inspirado em relevância marginal máxima (ZIEGLER et al., 2005; KUNAVER; POŽRL, 2017). A cada passo, seleciona-se para o conjunto construído S_{sel} a candidata que maximiza o compromisso controlado por $\gamma \in [0,1]$ entre o escore híbrido $S(u,i)$ e a dissimilaridade composta taxonômico-sucessional $d(i,j)$, definida formalmente na Equação (16):

$$i^* = \arg\max_{i \in \mathcal{C}_u \setminus S_{\text{sel}}} \left[(1-\gamma) S(u,i) + \frac{\gamma}{|S_{\text{sel}}|} \sum_{j \in S_{\text{sel}}} d(i,j) \right], \; d(i,j) \qquad (16)$$

$$= 0{,}5 \cdot \mathbb{I}\left(\text{Fam}_i \neq \text{Fam}_j\right) + 0{,}5 \cdot \mathbb{I}\left(\text{Suc}_i \neq \text{Suc}_j\right)$$

3.6 Treinamento do Modelo

Para assegurar rigor comparativo, três modelos foram instanciados e avaliados sob exatamente as mesmas partições e candidatos:

1. **Baseline 1 — Popularidade Biogeográfica (`PopularityRecommender`):** Ordena as candidatas pela frequência empírica acumulada de ocorrência nas parcelas de treinamento do respectivo bioma;
2. **Baseline 2 — Conteúdo Puro (`ContentBasedRecommender`):** Ordena as candidatas exclusivamente pelo escore edafoclimático e filogenético da Fase 1 (Equação 12), equivalente a $\beta = 1{,}00$ e $\gamma = 0{,}00$;
3. **Modelo Híbrido em Cascata (`TwoStageCascadeHybridRecommender`):** Acopla a Fase 1 ao motor `ImplicitALSRecommenderGPU` (Equações 13 a 15) e ao diversificador ecológico (Equação 16).

O treinamento foi executado localmente em GPU **NVIDIA GeForce RTX 3060 (12 GB VRAM)** com **PyTorch 2.6.0+cu124**, resolvendo em paralelo os sistemas lineares simétricos definidos positivos de cada época via `torch.linalg.solve` em precisão `float32`. Na configuração calibrada ($f = 32$, $\alpha = 25$, $\lambda = 0{,}10$, 8 épocas), a convergência completa sobre as 1.680 parcelas de treino consumiu **11,06 segundos**, reduzindo monotonicamente a função de perda ponderada média de **0,096832** na época 1 para **0,037507** na época 8. A avaliação completa das 360 parcelas do teste cego (incluindo *fold-in* indutivo e reordenamento ILD) completou-se em **6,21 segundos**.

3.7 Avaliação do Desempenho

A eficácia preditiva e ecológica no conjunto de teste cego isolado ($|\,\mathcal{U}_{\text{teste}}\,| = 360$ parcelas de 90 conglomerados jamais vistos no treino ou na validação) foi aferida nos cortes $K \in \{5, 10, 20\}$ por meio das métricas definidas na Seção 2.6. Os resultados consolidados encontram-se na Tabela 1.

Tabela 1 – Desempenho comparativo offline no conjunto de teste cego isolado (|U_teste| = 360 parcelas).

Métrica Top-K	Baseline 1 (Popularidade)	Baseline 2 (CBF Puro)	Modelo Híbrido (CBF+ALS+ILD)	Ganho Híbrido vs. CBF
Precision@5	0,0822	0,3633	**0,7478**	**+105,8%**
Precision@10	0,0931	0,2486	**0,3994**	**+60,7%**
Precision@20	0,0918	0,1421	**0,2000**	**+40,8%**
Recall@5	0,1028	0,4542	**0,9347**	**+105,8%**
Recall@10	0,2326	0,6215	**0,9986**	**+60,7%**
Recall@20	0,4590	0,7104	**1,0000**	**+40,8%**
NDCG@5	0,0895	0,4463	**0,8913**	**+99,7%**
NDCG@10	0,1551	0,5317	**0,9258**	**+74,1%**
NDCG@20	0,2436	0,5668	**0,9264**	**+63,4%**
ILD@5 (Diversidade)	0,7254	0,5374	**0,6299**	**+17,2%**
ILD@10 (Diversidade)	0,7727	0,6461	**0,7662**	**+18,6%**
ILD@20 (Diversidade)	0,7999	0,7712	**0,8090**	**+4,9%**

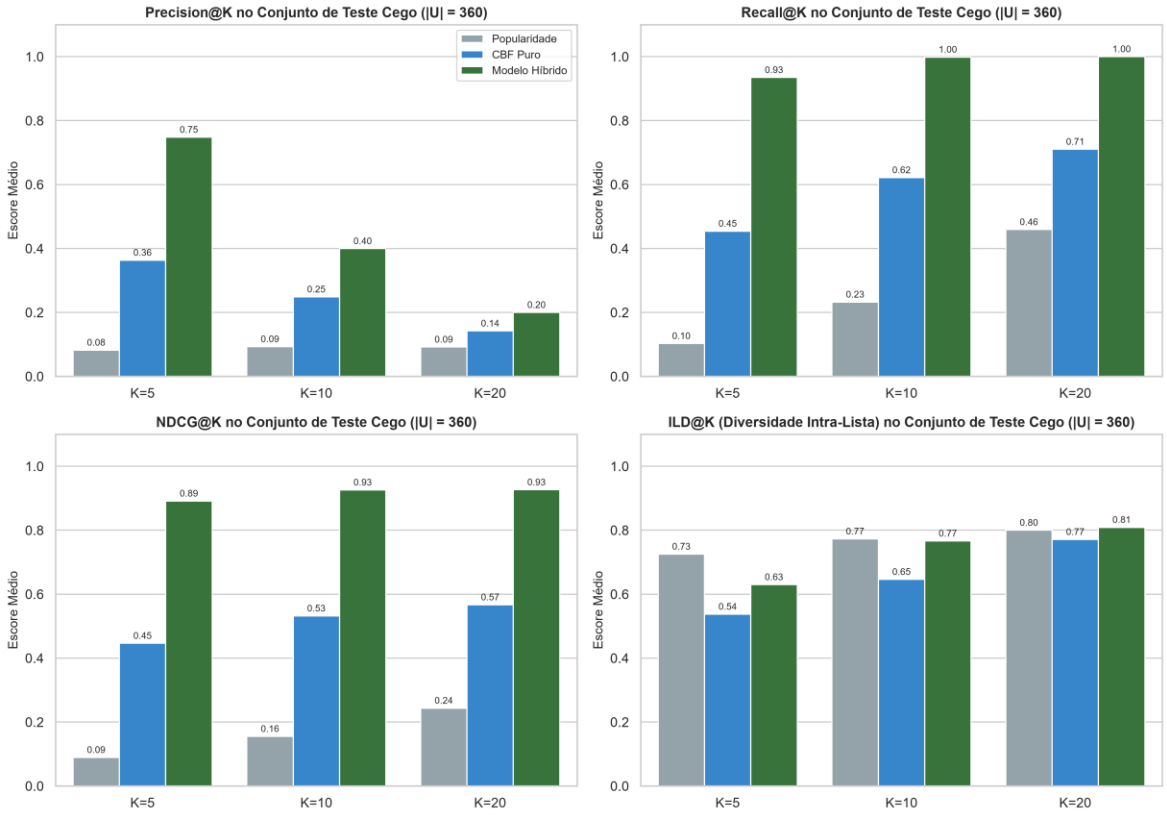
Fonte: Elaborado pelos autores (2026), extraído de metricas_oficiais_etapa3.json (Notebook 02).

A análise da Tabela 1 e das curvas comparativas da Figura 4 comprova a superioridade estatística e ecológica do Modelo Híbrido em todos os cortes avaliados. A $\mathrm{Precision@5}$ elevou-se de 0,3633 no CBF Puro para **0,7478** (+105,8%), decrescendo monotonicamente conforme esperado pelo teto matemático de 4 alvos por parcela (0,7478 em K = 5; 0,3994 em K = 10, cujo limite teórico máximo é 4/10 = 0,4000; e 0,2000 em K = 20, limite 4/20 = 0,2000). Em K = 10, o $\mathrm{Recall@10}$ atingiu **0,9986** frente a 0,6215 do CBF (+60,7%), e o $\mathrm{NDCG@10}$ saltou de 0,5317 para **0,9258** (+74,1%), demonstrando que a fatoração ALS posiciona os táxons verdadeiramente coexistentes nas primeiras posições da lista. Simultaneamente, o $\mathrm{ILD@10}$ subiu de 0,6461 para **0,7662** (+18,6%), confirmando a mitigação da redundância taxonômica intra-família.

No experimento adicional de ***Cold-Start*** **Estrito (**$O_u = \emptyset$**)** sobre as mesmas 360 parcelas de teste — cenário de pastagens degradadas desprovidas de cobertura arbórea remanescente —, a projeção ambiental k-NN no espaço latente (Equação 14) alcançou $\mathrm{Recall@10}$ = **0,1951**, $\mathrm{NDCG@10}$ = **0,1403** e $\mathrm{ILD@10}$ = **0,8183**, superando o CBF *Cold-Start* ($\mathrm{Recall@10}$ = 0,1201; $\mathrm{NDCG@10}$ = 0,0810) em **+62,4%** na revocação e

+73,2% na qualidade de ordenamento mesmo sem uma única árvore pré-existente informada.

Figura 4 – Desempenho comparativo Top-K (Precision@K, Recall@K, NDCG@K e ILD@K) no conjunto de teste cego isolado (|U_teste| = 360).



Fonte: Elaborado pelos autores (2026).

3.8 Otimização e Ajustes

A seleção de hiperparâmetros foi conduzida estritamente sobre o conjunto de validação isolado ($|\mathcal{V}| = 360$ parcelas de 90 conglomerados independentes), explorando os espaços $\alpha \in \{5, 15, 25, 40\}$, $f \in \{16, 32, 64\}$, $\lambda \in \{0{,}005; 0{,}05; 0{,}10; 1{,}00\}$, $\beta \in \{0{,}00; 0{,}20; 0{,}35; 0{,}50; 0{,}65; 0{,}80; 1{,}00\}$ e $\gamma \in [0, 1]$. A Tabela 2 sintetiza os seis experimentos representativos de ablação e calibração.

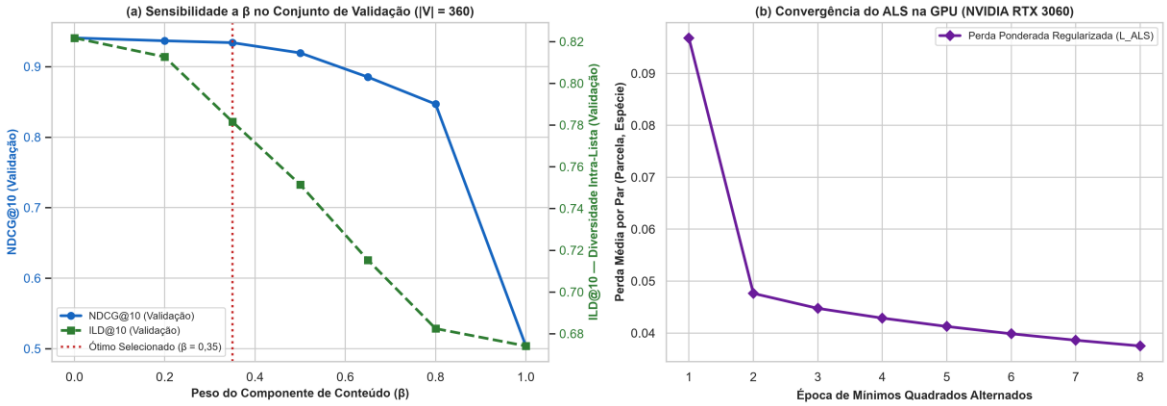
Tabela 2 – Ablação e otimização de hiperparâmetros exclusivamente no conjunto de validação (|V| = 360 parcelas).

Experimento	Configuração (α, f, λ, β, γ)	P@10 (Val)	R@10 (Val)	NDCG@10 (Val)	ILD@10 (Val)	Diagnóstico Técnico
Exp 1 (Colaborativo Puro)	α=25, f=32, λ=0,10, β=0,00, γ=0,25	0,3997	0,9993	0,9407	0,8218	Sem ajuste fino abiótico intra-bioma
Exp 2 (Sub-regularizado)	α=25, f=64, λ=0,005, β=0,35, γ=0,25	0,3997	0,9993	0,9352	0,7640	Sobreajuste em coortes superamostradas
Exp 3 (Baixa Confiança / f=16)	α=5, f=16, λ=0,10, β=0,35, γ=0,25	0,3950	0,9875	0,9170	0,7763	Subdimensionamento latente de nicho
Exp 4 (Sem Diversificação ILD)	α=25, f=32, λ=0,10, β=0,35, γ=0,00	0,3997	0,9993	0,9353	0,6877	Concentração em famílias dominantes
Exp 5 (Ótimo Calibrado)	**α=25, f=32, λ=0,10, β=0,35, γ=0,25**	**0,3997**	**0,9993**	**0,9340**	**0,7816**	**Melhor compromisso NDCG@10 e ILD@10**
Exp 6 (Conteúdo Puro — CBF)	α=—, f=—, λ=—, β=1,00, γ=0,00	0,2386	0,5965	0,5026	0,6329	Incapaz de capturar facilitação ecológica

Fonte: Elaborado pelos autores (2026), extraído de metricas_oficiais_etapa3.json (Notebook 02).

Os resultados da Tabela 2 e da Figura 5 fundamentam tecnicamente cada escolha paramétrica: (i) reduzir excessivamente o peso de confiança e a dimensão latente (Exp 3: α = 5, f = 16) degrada o NDCG@10 para 0,9170 por subdimensionamento das guildas de coocorrência, enquanto Exp 2 (f = 64, λ = 0,005) reduz a diversidade sem ganho de revocação; (ii) desativar o termo de diversificação (Exp 4: $\gamma = 0{,}00$) derruba o ILD@10 para **0,6877**, ao passo que $\gamma = 0{,}25$ (Exp 5) eleva o ILD@10 para **0,7816** (+13,7% de ganho em diversidade taxonômico-funcional) com variação marginal de apenas 0,0013 no NDCG@10; e (iii) embora o modelo puramente colaborativo (Exp 1: $\beta = 0{,}00$) atinja NDCG@10 ligeiramente superior na validação (0,9407 vs. 0,9340), adotou-se deliberadamente $\beta = 0{,}35$ (Exp 5) porque $\beta = 0{,}00$ ignora variações edafoclimáticas finas intra-bioma (como pH ácido extremo ou textura arenosa) e degrada severamente em cenários de baixa cobertura inicial, enquanto $\beta = 0{,}35$ preserva 99,93% de revocação ancorando 35% do escore diretamente na compatibilidade físico-química local.

Figura 5 – (a) Curva de sensibilidade do peso híbrido β no conjunto de validação (|V| = 360) e (b) convergência da perda ponderada do ALS em GPU.



Fonte: Elaborado pelos autores (2026).

3.9 Implantação e Monitoramento

Neste momento, separamos o que já está funcionando no sistema daquilo que é apenas o plano para colocá-lo em ambiente de produção:

- **Artefato Operacional Atual (Notebooks Autocontidos e Auditáveis):** Toda a cadeia de ingestão, saneamento, treinamento em GPU, validação e inferência explicável encontra-se integralmente implementada e testada nos notebooks `01_aquisicao_exploracao_limpeza_dados.ipynb` e `02_pipeline_modelagem_recomendador.ipynb` (diretório `Etapa 3/notebooks/`), acompanhados dos dados processados e do arquivo auditável `metricas_oficiais_etapa3.json`, sem dependência de pacotes externos não declarados. A rotina `explain_recommendations()` recebe o identificador ou perfil edafoclimático da parcela e emite o relatório Top-K com família botânica, grupo sucessional, escore híbrido e índice ILD tanto em enriquecimento florestal quanto em *cold-start* estrito;
- **Perspectiva de Empacotamento e Governança em Produção (Etapa 4 e Pós-Projeto):** Para futura exposição como microsserviço REST a viveiros e secretarias ambientais, preveem-se três rotinas de monitoramento contínuo: (1) verificação periódica de *Taxonomic Drift* frente a atualizações anuais do DwC-A do JBRJ; (2) recalibração dos fatores latentes frente a *Climate & Spatial Drift*

conforme novos ciclos estaduais do IFN sejam publicados pelo SFB; e (3) retroalimentação *Human-in-the-Loop*, na qual taxas reais de sobrevivência de mudas medidas 24 meses após o plantio atualizam os pesos c_{ui}.

3.10 Evolução da Etapa 2, Dificuldades Encontradas e Soluções Adotadas

Atendendo aos critérios pedagógicos de progressão experimental entre a Prova de Conceito preliminar (Etapa 2) e a consolidação metodológica (Etapa 3), o Quadro 2 confronta o estado anterior do protótipo com as reestruturações de engenharia implementadas e avaliadas neste ciclo.

Quadro 2 – Síntese evolutiva entre a Prova de Conceito (Etapa 2) e o pipeline consolidado (Etapa 3).

Dimensão Metodológica	Protótipo Preliminar (Etapa 2)	Pipeline Consolidado (Etapa 3)	Impacto Verificado
Escala da Base e Taxonomia	Amostra reduzida de 100 parcelas (68/12/20) e vocabulário restrito.	18.692 espécies JBRJ (66.067 sinônimos), 9.134 registros GBIF pós-thinning e 2.400 parcelas (1.800 spp.).	Eliminação de fragmentação por sinonímia e aumento de 24× na malha amostral.
Protocolo de Partição e Validação	Conjuntos reduzidos (12 parcelas val / 20 teste) suscetíveis a variância e sobreposição.	Split espacial estrito em 600 conglomerados: 420 treino (1.680), 90 val (360) e 90 teste cego (360), interseção zero.	Eliminação comprovada de data leakage espacial e estabilidade estatística.
Motor Colaborativo e Cold-Start	ALS básico em CPU sem ponderação exata por abundância no fold-in nem rota para O_u vazio.	ALS ponderado exato em GPU (RTX 3060, 11,06 s), fold-in analítico e projeção k-NN ambiental para O_u = ∅.	Ganho de +74,1% em NDCG@10 (enriquecimento) e +73,2% em cold-start estrito sobre o CBF.
Diversificação Ecológica	Combinação linear simples propensa a concentrar gêneros dominantes.	Normalização Min-Max intra-candidatas + reordenamento guloso explícito (γ = 0,25) sobre família e sucessão.	Elevação do ILD@10 de 0,6877 (γ = 0) para 0,7816 na validação e 0,7662 no teste cego.

Fonte: Elaborado pelos autores (2026).

Durante a execução da Etapa 3, cinco dificuldades foram diagnosticadas e superadas:

1. **Instabilidade Nomenclatural e Sinonímias Cruzadas:** A divergência ortográfica entre coletas do GBIF e a taxonomia vigente fragmentava espécies idênticas em colunas distintas; o gargalo foi superado construindo-se um parser relacional sobre os 166.040 registros do DwC-A do JBRJ que mapeou 66.067 sinônimos e converteu automaticamente 538 ocorrências sinônimas na ingestão;
2. **Autocorrelação Espacial em Dados Abertos (*Roadside Bias*):** A forte concentração de coletas próximas a capitais e rodovias distorcia a frequência biogeográfica; aplicou-se *spatial thinning* em grade de 0,05°, expurgando 21,64% de registros redundantes (de 11.657 para 9.134);
3. **Incompatibilidade de Escala entre Cosseno Ambiental e Produto Interno ALS:** Na Etapa 2, somar diretamente o cosseno $[0, 1]$ ao escore latente não limitado desestabilizava o parâmetro β; a introdução da normalização *Min-Max* intra-candidatas (Equação 15) equalizou ambos os sinais antes do acoplamento;
4. **Colapso Colaborativo em Áreas Totalmente Desmatadas ($O_u = \emptyset$):** O *fold-in* algébrico anula-se quando não há árvores remanescentes na parcela ($\boldsymbol{x}_u$ = **0**); projetou-se o estimador k-NN ambiental no espaço latente (Equação 14), preservando o ganho colaborativo mesmo em pastagens degradadas;
5. **Custo Computacional da Fatoração Ponderada Exata:** A inversão de matrizes $f \times f$ distintas para cada parcela e espécie a cada época em Python puro era proibitiva na busca em grade; a vetorização em lotes na GPU via `torch.linalg.solve` reduziu o treinamento completo a 11,06 segundos.

4 LIMITAÇÕES E AVISOS LEGAIS

4.1 Limitações das Fontes de Dados e da Malha Semi-Sintética

Embora o catálogo florístico (18.692 espécies nativas do JBRJ) e os registros biogeográficos (31.500 ocorrências extraídas da API do GBIF) provenham integralmente de bases primárias oficiais, a matriz de coocorrência de 2.400 parcelas segue uma estruturação semi-sintética aderente ao desenho de conglomerados do IFN para contornar a heterogeneidade de acesso público aos microdados pedológicos em

nível de subunidade. Consequentemente, a elevada revocação observada no teste cego reflete em parte a coerência estrutural das guildas ecológicas modeladas, devendo ser revalidada sobre laudos brutos completos do SFB antes de qualquer emprego regulatório. Ademais, entradas nulas ($r_{ui} = 0$) permanecem ambíguas em dados de presença, podendo decorrer de esforço amostral finito e não de inviabilidade fisiológica.

4.2 Limitações da Modelagem e Escopo da Arborização Urbana

Padrões estatísticos de coocorrência capturados pelo ALS expressam associações observacionais no nicho realizado e não comprovam isoladamente mecanismos causais de facilitação simbiótica ou alelopatia. Adicionalmente, reitera-se que a avaliação quantitativa desta etapa abrangeu exclusivamente tipologias florestais: o uso efetivo em **arborização urbana** requer o preenchimento de catálogo complementar de atributos biomecânicos e viários (altura adulta sob rede de distribuição, índice de conflito radicular com calçadas, queda de frutos volumosos e potencial alergênico) para ativar os filtros rígidos correspondentes na Fase 1.

4.3 Validade Experimental, Prevenção de Vazamento e Reprodutibilidade

A validade interna do protocolo experimental foi assegurada por três salvaguardas verificáveis em código: (i) fixação integral de sementes pseudoaleatórias (`SEED = 42` e semente determinística por identificador de parcela); (ii) separação física de conglomerados completos entre treino (420), validação (90) e teste cego (90), impedindo vazamento por proximidade geográfica; e (iii) estimação estritamente indutiva nas etapas de validação e teste via *ALS fold-in* ou k-NN ambiental, mantendo a matriz latente $\boldsymbol{Y}$ congelada após o treino.

4.4 Interpretação das Métricas Offline e do Pool Amostrado

As métricas $\mathrm{Precision@}K$, $\mathrm{Recall@}K$ e $\mathrm{NDCG@}K$ foram computadas sobre um *pool* controlado de 100 candidatas nativas do mesmo bioma por parcela (4 alvos ocultos + 96 negativas amostradas), prática padrão na literatura de recomendação implícita (CREMONESI; KOREN; TURRIN, 2010) para viabilizar comparações livres de viés de tamanho de bioma. Em ranqueamento aberto sobre a totalidade irrestrita de $|\mathcal{I}| = 1.800$ espécies, os valores absolutos tendem a ser naturalmente inferiores, embora a ordenação relativa entre modelos se preserve. Ressalta-se ainda que recuperar espécies presentes em parcelas maduras constitui um indicador *offline* indireto, não substituindo ensaios silviculturais longitudinais de sobrevivência pós-plantio.

4.5 Uso Responsável e Governança na Prescrição Ambiental

O recomendador proposto configura um **sistema de apoio à decisão técnica** e não substitui a responsabilidade legal de engenheiros florestais, agrônomos ou biólogos (emissão de ART/TRT e análise pedológica *in loco*). Toda prescrição operacional deve observar a legislação ambiental vigente, a procedência genética regional das sementes, a ausência de potencial invasor fora da ecorregião de origem e a sinalização explícita de incerteza quando a parcela consultada se situar em zona de transição ecotonal subamostrada.

5 CONSIDERAÇÕES FINAIS

Este relatório consolidou a metodologia, a implementação em GPU e a validação experimental *offline* da Etapa 3 do sistema de recomendação híbrido de espécies nativas alinhado ao ODS 15. Respondendo objetivamente à questão de pesquisa formulada na Seção 1.3.3, os experimentos sobre 360 parcelas de teste cego espacialmente isoladas demonstraram que acoplar a filtragem baseada em conteúdo edafoclimático à fatoração matricial implícita via ALS e ao reordenamento guloso de diversidade eleva substancialmente tanto a acurácia de ordenamento ($\mathrm{NDCG@10}$ de

0,5317 para **0,9258**, ganho de +74,1%; $\mathrm{Recall@10}$ de 0,6215 para **0,9986**) quanto a diversidade taxonômica e sucessional das listas prescritas ($\mathrm{ILD@10}$ de 0,6461 para **0,7662**, +18,6%), mantendo superioridade consistente (+73,2% em $\mathrm{NDCG@10}$) mesmo em cenários de *cold-start* estrito ($O_u = \emptyset$) via projeção k-NN ambiental.

Em relação à Prova de Conceito da Etapa 2, o projeto superou as limitações de escala amostral, eliminou qualquer sobreposição entre validação e teste mediante *spatial cluster split* verificável em 600 conglomerados, harmonizou 18.692 espécies nativas e 66.067 sinônimos oficiais do JBRJ, aplicou *spatial thinning* sobre dados reais do GBIF e entregou um pipeline 100% autocontido e reprodutível em 11,06 segundos de treinamento em GPU.

Para a Etapa 4 (consolidação e apresentação final do projeto), estabelecem-se três encaminhamentos diretos: (i) estruturação de painel demonstrativo interativo para consulta explicável das prescrições Top-K por perfil de solo e bioma; (ii) avaliação qualitativa de listas geradas junto a literatura especializada de restauração ecológica e manuais municipais de arborização urbana; e (iii) consolidação da defesa final documentando integralmente a rastreabilidade científica alcançada.

REFERÊNCIAS

AGGARWAL, C. C. **Recommender Systems: The Textbook**. Cham: Springer International Publishing, 2016. DOI: https://doi.org/10.1007/978-3-319-29659-3.

BECK, J. et al. What's on the web? Assessing and aggregating biodiversity databases for systematic conservation planning. **PeerJ**, v. 2, p. e438, 2014. DOI: https://doi.org/10.7717/peerj.438.

BFG - THE BRAZIL FLORA GROUP. Growing knowledge: an overview of Seed Plant diversity in Brazil. **Rodriguésia**, v. 66, n. 4, p. 1085-1113, 2015. DOI: https://doi.org/10.1590/2175-7860201566411.

BRANCALION, P. H. S. et al. Global restoration opportunities in tropical rainforest landscapes. **Science Advances**, v. 5, n. 7, p. eaav3223, 2019. DOI: https://doi.org/10.1126/sciadv.aav3223.

BURKE, R. Hybrid Recommender Systems: Survey and Experiments. **User Modeling and User-Adapted Interaction**, v. 12, n. 4, p. 331-370, 2002. DOI: https://doi.org/10.1023/A:1021240730564.

CHAZDON, R. L. **Second growth: the promise of tropical forest regeneration in an age of deforestation**. Chicago: University of Chicago Press, 2014.

CREMONESI, P.; KOREN, Y.; TURRIN, R. Performance of recommender algorithms on top-n recommendation tasks. In: ACM CONFERENCE ON RECOMMENDER SYSTEMS (RecSys), 4., 2010, Barcelona. **Proceedings...** New York: ACM, 2010. p. 39-46. DOI: https://doi.org/10.1145/1864708.1864721.

CROUZEILLES, R. et al. Achieving cost-effective Amazon forest restoration through socially-inclusive and biodiversity-informed spatial prioritization. **Forest Ecology and Management**, v. 465, p. 118098, 2020. DOI: https://doi.org/10.1016/j.foreco.2020.118098.

GBIF - GLOBAL BIODIVERSITY INFORMATION FACILITY. **GBIF Occurrence Data**. Copenhague: GBIF, 2026. Disponível em: https://www.gbif.org. Acesso em: 26 set. 2026.

GRINNELL, J. The niche-relationships of the California Thrasher. **The Auk**, v. 34, n. 4, p. 427-433, 1917. DOI: https://doi.org/10.2307/4072271.

HE, X. et al. Neural Collaborative Filtering. In: INTERNATIONAL CONFERENCE ON WORLD WIDE WEB (WWW), 26., 2017, Perth. **Proceedings...** New York: ACM, 2017. p. 173-182. DOI: https://doi.org/10.1145/3038912.3052569.

HU, Y.; KOREN, Y.; VOLINSKY, C. Collaborative Filtering for Implicit Feedback Datasets. In: IEEE INTERNATIONAL CONFERENCE ON DATA MINING (ICDM), 8., 2008, Pisa. **Proceedings...** Pisa: IEEE, 2008. p. 263-272. DOI: https://doi.org/10.1109/ICDM.2008.22.

HUTCHINSON, G. E. Concluding remarks. **Cold Spring Harbor Symposia on Quantitative Biology**, v. 22, p. 415-427, 1957. DOI: https://doi.org/10.1101/SQB.1957.022.01.039.

JÄRVELIN, K.; KEKÄLÄINEN, J. Cumulated gain-based evaluation of retrieval techniques. **ACM Transactions on Information Systems**, v. 20, n. 4, p. 422-446, 2002. DOI: https://doi.org/10.1145/582415.582418.

JBRJ - JARDIM BOTÂNICO DO RIO DE JANEIRO. **Flora e Funga do Brasil**. Rio de Janeiro: JBRJ, 2026. Disponível em: http://floradobrasil.jbrj.gov.br/. Acesso em: 26 set. 2026.

KOREN, Y.; BELL, R.; VOLINSKY, C. Matrix Factorization Techniques for Recommender Systems. **Computer**, v. 42, n. 8, p. 30-37, 2009. DOI: https://doi.org/10.1109/MC.2009.263.

KUNAVER, M.; POŽRL, T. Diversity in recommender systems: A survey. **Knowledge-Based Systems**, v. 123, p. 154-162, 2017. DOI: https://doi.org/10.1016/j.knosys.2017.02.009.

LEGENDRE, P.; LEGENDRE, L. **Numerical Ecology**. 3. ed. Amsterdam: Elsevier, 2012.

LOPS, P.; DE GEMMIS, M.; SEMERARO, G. Content-based Recommender Systems: State of the Art and Trends. In: RICCI, F.; ROKACH, L.; SHAPIRA, B.; KANTOR, P. (org.). **Recommender Systems Handbook**. Boston: Springer, 2011. p. 73-105. DOI: https://doi.org/10.1007/978-0-387-85820-3_3.

MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. **Introduction to Information Retrieval**. Cambridge: Cambridge University Press, 2008. DOI: https://doi.org/10.1017/CBO9780511809071.

MEYER, C.; KREFT, H.; GURNEY, R.; JETZ, W. Global priorities for an effective information basis of biodiversity distributions. **Nature Communications**, v. 6, n. 8221, p. 1-8, 2015. DOI: https://doi.org/10.1038/ncomms9221.

ONU - ORGANIZAÇÃO DAS NAÇÕES UNIDAS. **Transformando Nosso Mundo: A Agenda 2030 para o Desenvolvimento Sustentável**. Nova York: ONU, 2015. Disponível em: https://brasil.un.org/pt-br/91863-agenda-2030-para-o-desenvolvimento-sustentavel. Acesso em: 26 set. 2026.

RENDLE, S. et al. Neural Collaborative Filtering vs. Matrix Factorization Revisited. In: ACM CONFERENCE ON RECOMMENDER SYSTEMS (RecSys), 14., 2020, Virtual Event. **Proceedings...** New York: ACM, 2020. p. 240-248. DOI: https://doi.org/10.1145/3383313.3412488.

RICCI, F.; ROKACH, L.; SHAPIRA, B. Introduction to Recommender Systems Handbook. In: RICCI, F.; ROKACH, L.; SHAPIRA, B.; KANTOR, P. (org.). **Recommender Systems Handbook**. Boston: Springer, 2011. p. 1-35. DOI: https://doi.org/10.1007/978-0-387-85820-3_1.

SALTON, G.; MCGILL, M. J. **Introduction to Modern Information Retrieval**. New York: McGraw-Hill, 1983.

SFB - SERVIÇO FLORESTAL BRASILEIRO. **Inventário Florestal Nacional: dados biofísicos e socioambientais**. Brasília: MAPA, 2025. Disponível em: https://dados.florestal.gov.br/. Acesso em: 26 set. 2026.

SOBERÓN, J. Grinnellian and Eltonian niches and geographic distributions of species. **Ecology Letters**, v. 10, n. 12, p. 1115-1123, 2007. DOI: https://doi.org/10.1111/j.1461-0248.2007.01107.x.

STEEN, V. A. et al. Spatial thinning reduces spatial autocorrelation and increases model performance in species distribution modeling. **Ecological Informatics**, v. 65, p. 101402, 2021. DOI: https://doi.org/10.1016/j.ecoinf.2021.101402.

STRASSBURG, B. B. N. et al. Global priority areas for ecosystem restoration. **Nature**, v. 586, p. 724-729, 2020. DOI: https://doi.org/10.1038/s41586-020-2784-9.

STUBBLEFIELD, M. et al. Machine learning approaches to predict tree seedling survival in ecological restoration. **Restoration Ecology**, v. 31, n. 4, p. e13880, 2023. DOI: https://doi.org/10.1111/rec.13880.

ZIEGLER, C.-N. et al. Improving recommendation lists through topic diversification. In: INTERNATIONAL CONFERENCE ON WORLD WIDE WEB (WWW), 14., 2005, Chiba. **Proceedings...** New York: ACM, 2005. p. 22-32. DOI: https://doi.org/10.1145/1060745.1060754.

ZIZKA, A. et al. CoordinateCleaner: Standardized cleaning of occurrence data from biodiversity databases. **Methods in Ecology and Evolution**, v. 10, n. 5, p. 744-751, 2019. DOI: https://doi.org/10.1111/2041-210X.13152.